

TEMA 3 – HOJA DE EJERCICIOS II

Se plantean una serie de ejercicios relacionados con la representación de textos mediante modelos probabilísticos y estadísticos.

Ejercicio 1. Probabilistic Topic Model. LDA.

Dado un fichero en formato JSON con noticias se quiere obtener los diferentes topics utilizando LDA. En este primer ejercicio se proporciona el notebook completo hacerlo, los pasos son los siguientes:

1. Lectura del fichero y carga de datos.
2. Preprocesamiento básico de los textos.
3. Entrenamiento del algoritmo Latent Dirichlet Allocation de sklearn. Se recomienda ver la documentación de la [librería](#) para ver los diferentes parámetros del algoritmo.
4. Visualización de resultados.
5. Evaluación de los resultados.

Se pide ejecutar el código proporcionado y realizar ajustes sobre él para ver cómo cambian los resultados:

1. Cambiar el número de topics, ahora está a 2, pero revisando el fichero con las noticias, en realidad serían más.
2. Cambiar el preprocesamiento de los textos, eliminando stopwords al menos y lo que se considere para ver si mejoran los resultados.

¿Cómo impacta en los resultados los diferentes cambios de los apartados anteriores?

Ejercicio 2. Probabilistic Topic Model. LDA. Inferencia.

Sobre la base del ejercicio anterior se quiere añadir una nueva noticia y realizar inferencia para ver los topics en ella.

El texto de la noticia a inferir es el siguiente:

“Trump ordena suspender toda la ayuda militar de Estados Unidos a Ucrania tras su bronca a Zelenski.”

Se tiene que mostrar en qué % se ajusta la noticia a los diferentes topics existentes.

Ejercicio 3. Statistic Language Model.

Utilizando n-gramas y el corpus Reuters de NLTK se van a predecir palabras. Se pide lo siguiente:

1. Imprimir el número completo de trigramas de palabras de todas las sentencias del corpus.
2. Imprimir el número de veces que la palabra “economists” sigue a “what the”.
3. ¿Y si preguntamos por una palabra que no existe? Por ejemplo, imprimir el número de veces que “nonexistingword” sigue a “what the”.
4. ¿Cómo saber cuántas oraciones comienzan por “The”?
5. Se pueden transformar las frecuencias en probabilidades para responder a las preguntas 3 y 4 con probabilidades.
6. Si quisiéramos generar texto se podría. ¿Cuáles serían las palabras más probables que siguen a “The Market”?

Nota: Utilizar la clase DefaultDict de Python (from collections import defaultdict)