

Procesamiento del Lenguaje Natural I

TEMA 7. Reconocimiento de Entidades Nombradas

Soto Montalvo Herranz

Objetivos

- Presentar uno de los problemas típicos en PLN: Reconocimiento de Entidades Nombradas.
- Introducir el concepto de Entidad Nombrada.
- Ver posibles enfoques de cómo hacer reconocimiento de entidades en textos.

Índice

- Introducción
- ¿Qué es NER?
- Principales enfoques para NER
- Dificultades en NER
- Bibliografía

Índice

- **Introducción**
- ¿Qué es NER?
- Principales enfoques para NER
- Dificultades en NER
- Bibliografía

Introducción

- Contexto

- Recuperación de información (IR, *Information Retrieval*):** proceso de buscar y extraer datos relevantes de grandes volúmenes de información en respuesta a una consulta o necesidad específica.



Introducción

- Contexto

- Extracción de Información (IE, *Information Extraction*):** proceso de extraer información estructurada relevante de datos no estructurados.




Imagen: [1]

Introducción

- Extracción de Información. Tareas:
 - Reconocimiento de Entidades Nombradas

El **Inter** **LOC**, un equipo más despiadado que sensible, acabó cruelmente con la excitante aventura europea del **Barça** **LOC** en **Milán** **LOC**, a las puertas de **Múnich** **PER**, el escenario de la final del día 31. **La apasionante trayectoria azulgrana** **MISC**, por inesperada y divertida, protagonizada por un equipo mayormente juvenil y desacomplejado, quedó cortada de cuajo por un equipo italiano tan adulto como maquiavélico, alejado de los focos mediáticos y refugiado en el **estadio Giuseppe Meazza** **LOC**. **Los nerazzurri** **MISC** son, a fin de cuentas, el antídoto del Barcelona.

Kashmir **LOC** is an ethnically diverse **Himalayan** **PERSON** region famed for the beauty of its lakes, meadows and snow-capped mountains.

Even before **India** **GPE** and **Pakistan** **GPE** won their independence from **Britain** **GPE** in **August 1947** **DATE**, the area was hotly contested.

Under the partition plan provided by the **Indian** **NORP** Independence Act, **Muslim** **NORP** - majority **Kashmir** **LOC** was free to accede to either **India** **GPE** or **Pakistan** **GPE**.

The maharaja (local ruler), **Hari Singh** **PERSON**, initially wanted **Kashmir** **LOC** to become independent - but in **October 1947** **DATE** chose to join **India** **GPE**, in return for its help against an invasion of tribesmen from **Pakistan** **GPE**.

Imágenes generadas con: <https://demos.explosion.ai/displacy-ent?>

Introducción

- Extracción de Información. Tareas:
 - Resolución de correferencia

"I loved the cheesecake because it reminded me of the recipe my mother used to make." James said.




"James loved the cheesecake because the cheesecake reminded James of the recipe James' mother used to make." James said.

Imagen: [2]

Introducción

- Extracción de Información. Tareas:
 - Extracción de relaciones



Relationship Extraction



Imagen: [3]

Índice

- Introducción
- ¿Qué es NER?
- Principales enfoques para NER
- Dificultades en NER
- Bibliografía

¿Qué es NER?

- Entidad Nombrada (EN o NE, *Named Entity*)
 - Unidad de información fundamental que se refiere a nombres propios que se pueden clasificar en varias categorías.
 - Una EN se refiere a un “objeto real” que tiene asignado un determinado nombre (por ejemplo, una persona, un país, el título de un libro, etc.)
 - Las categorías genéricas más aceptadas son:
 - Personas (Paul Newman, Paul, Presidente Barack Obama, . . .)
 - Lugares (Madrid, Embalse de Buendía, Estados Unidos, Calle Mayor, . . .)
 - Organizaciones (Ministerio de Industria, Apple, Ayuntamiento de Madrid, Universidad Rey Juan Carlos, . . .)
 - Se pueden añadir otras categorías como expresiones temporales (fecha, hora), cantidades numéricas (porcentajes), etc.

¿Qué es NER?

- Entidad Nombrada (EN o NE, *Named Entity*)
 - Puede también haber otras categorías más específicas dependiendo del dominio de aplicación.




Imagen: [1]




Imagen: [4]

¿Qué es NER?

- El Reconocimiento de Entidades Nombradas (NER, *Named Entity Recognition*) es la tarea encargada de reconocer las EN en los textos
- ¿Por qué es importante?
 - Es crucial para la extracción de relaciones
 - Es una tarea necesaria o imprescindible para otras muchas tareas de PLN (recuperación de información, búsquedas de respuestas, etc.
- Los sistemas NER suelen formar parte del pipeline de análisis lingüístico.

Índice

- Introducción
- ¿Qué es NER?
- **Principales enfoques para NER**
- Dificultades en NER
- Bibliografía

Principales enfoques para NER

- Los principales enfoques aplicados a NER son:
 - Enfoques basados en diccionarios (listas de nombres, organizaciones, etc.) o reglas (expresiones regulares).
 - Enfoques basados en aprendizaje automático: algoritmos clásicos (CRF) versus aprendizaje profundo.

Principales enfoques para NER

- Enfoques NER basados en diccionarios y reglas:
 - Los diccionarios proporcionan listas de entidades.
 - Las reglas son patrones para reconocer EN no presentes en los diccionarios:
 - “Organización de “ => ORG (“Organización de Naciones Unidas”)
 - “Calle “ => LOC (“Calle Mayor”)
 - “Universidad de “ + lugar => ORG (“Universidad de Oviedo”)
 - [Mr.|Mrs.|Dr.]...” + Xxxx => PER
- Los sistemas basados en este enfoque suelen tener una precisión alta, pero un recall bajo.

Principales enfoques para NER

- Enfoques NER basados en aprendizaje automático:
 - La tarea se plantea como una tarea de clasificación de tokens (*sequence labeling*) => el texto se tokeniza y cada token se clasifica de acuerdo a una etiqueta.
 - El conjunto de etiquetas o formato más utilizado es el standard IOB (inside-outside-beginning).
 - El prefijo B- indica que el token es el inicio de una entidad
 - El prefijo I- indica que el token está dentro de una entidad
 - El prefijo O indica que el token no pertenece a una entidad
 - El objetivo es entrenar un modelo capaz de clasificar cada token en una oración.

Principales enfoques para NER

- Standard IOB: Conjunto de etiquetas: O, B-X, I-X, donde X es un tipo de entidades (LOC, ORG, PER, etc).

Winnie	B-PERSON
the	I-PERSON
Pooh	I-PERSON
is	O
naïve	O
and	O
slow-witted	O

Token	Etiqueta	Tipo de Entidad
Yolanda	B	PER
Díaz	I	PER
visitó	O	-
hoy	O	-
la	O	-
Comisión	B	ORG
Europea	I	ORG
.	O	-

Imagen: [1]

BILUO SCHEME

- B – Token is the **beginning** of a multi-token entity.
- I – Token is **inside** a multi-token entity.
- L – Token is the **last** token of a multi-token entity.
- U – Token is a single-token **unit** entity.
- O – Token is **outside** an entity.

Esquema de anotación que utiliza spaCy

Principales enfoques para NER


- Enfoques NER basados en aprendizaje automático:
 - Basados en algoritmos clásicos
 - Hay que definir un conjunto de características para representar cada token.
 - Basados en aprendizaje profundo
 - No es necesario representar cada token con un conjunto de características.
 - Simplemente se tokeniza el texto y la red profunda aprenderá durante el entrenamiento las características (vectores) más adecuados para cada token.
 - Se combinan diferentes capas para resolver la tarea de clasificación de tokens.
- Con ambos enfoques se necesitará un dataset de entrenamiento con los tokens anotados siguiendo el esquema de anotación IOB.

Principales enfoques para NER

- Enfoques NER basados en algoritmos clásicos:
 - Las características más habituales para NER son:
 - Token y lema (“Madrid” como token y “Madrid” como lema)
 - PoS tag: NNP (nombre propio)
 - Patrón ortográfico de una palabra (“Madrid” -> Xxxxxx)
 - Afijos (prefijos y sufijos)
 - Si el token está en un diccionario o base de datos => es un valor booleano.
 - Información de contexto: para representar un token el conjunto de características se extiende también a los tokens del contexto.
 - Las características también se obtienen para los tokens que rodean al token que se está representando.
 - Ejemplo: “La ciudad Madrid es grande”.
 - Si se representa el token “Madrid” y se tiene una ventana de contexto de tamaño 2.
 - Las características de los 2 tokens anteriores y los dos siguientes se añadirán también a la representación del token “Madrid”.

Principales enfoques para NER

- Enfoques NER basados en aprendizaje profundo
 - Ejemplo de arquitectura que ha dado buenos resultados para NER



Principales enfoques para NER

- Enfoques NER basados en aprendizaje profundo
 - Ejemplo de arquitectura que ha dado buenos resultados para NER




Imagen: [1]

Índice

- Introducción
- ¿Qué es NER?
- Principales enfoques para NER
- **Dificultades en NER**
- Bibliografía

Dificultades en NER

- Cosas que pueden afectar en la tarea de reconocer Entidades Nombradas:
 - **Abreviaturas.** A veces no se reconocen como entidad (“N.Y.” con “Nueva York”)
 - **Distintas menciones.** Una misma entidad puede aparecer con diferentes menciones:
 - “Madrid”, “Capital de España”
 - “Barak Obama”, “presidente Obama”, “Mr. Obama”
 - **Múltiples clasificaciones.** Una misma mención puede clasificarse con diferentes categorías.
 - “Toledo” (LOC), ciudad – “Toledo” (PERSON), apellido (“Goya Toledo”)
 - **Errores ortográficos.** Pueden provocar la omisión de entidades.
 - **Anidamiento de Entidades.** “**Madrid** Fashion Week”

Dificultades en NER

- Cosas que pueden afectar en la tarea de reconocer Entidades Nombradas:
 - En algunos dominios se puede complicar aún más. Por ejemplo, en el dominio médico podemos encontrar entidades representadas por frases:

Título científico: Estudio de Fase 3 Aleatorizado para Evaluar la Seguridad y la Actividad Antiviral de Remdesivir (GS-5734™) en

Participantes con infección grave por el COVID-19.

Indicación pública: Enfermedad por el Coronavirus 2019 (COVID-19)

Criterios de inclusión:

1) Disposición y capacidad para otorgar el consentimiento informado por escrito antes de realizar los procedimientos del estudio

2) Edad ≥ 18 años

3) Infección por el SARS-CoV-2 confirmada mediante PCR ≤ 4 días antes de la aleatorización

4) Hospitalización con fiebre, definida como una temperatura $\geq 36,6$ °C en la axila, $\geq 37,2$ °C en la boca y $\geq 37,8$ °C en el recto

Imagen: [4]

Bibliografía

- [1] Segura Bedmar, I. Desarrollo de aplicaciones PLN basadas en aprendizaje profundo. Reconocimiento de entidades (Named Entity Recognition). Procesamiento del Lenguaje Natural con Aprendizaje Profundo. Máster en Ciencia y Tecnología Informática. 2023. ([Enlace](#))
- [2] Cook, M. Coreference Resolution. ([Enlace](#))
- [3] Geeks for Geeks. Relationship Extraction in NLP. 2025. ([Enlace](#))
- [4] Campillos-Llanos, L., Valverde-Mateos, A., Capllonch-Carrión, A. y Moreno-Sandoval, A. A clinical trials corpus annotated with UMLS entities to enhance the access to evidence-based medicine. BMC Medical Informatics and Decision Making, 21, 69 (2021). <https://doi.org/10.1186/s12911-021-01395-z>