

TEMA 2 – HOJA DE EJERCICIOS V

Se proponen diferentes ejercicios relacionados con el análisis semántico. Se deberá utilizar WordNet de NLTK (<https://www.nltk.org/api/nltk.corpus.reader.wordnet.html>).

1. Utilizando WordNet, obtiene los diferentes sentidos de la palabra “fight”. Para cada uno de ellos imprime su definición, los diferentes lemas asociados al mismo sentido y, también, ejemplos de uso de cada sentido.

En la siguiente figura se muestra parte de la salida que se pide:

```
Def: an aggressive willingness to compete  
['competitiveness', 'fight']  
['the team was full of fight']  
Def: an intense verbal dispute  
['fight']  
['a violent fight over the bill is expected in the Senate']
```

2. Haz lo mismo que en el ejercicio anterior, pero obteniendo los *synsets* solo cuando la categoría de la palabra sea un verbo. ¿Qué ha cambiado?
3. Obtener todos los sentidos de “bank” cuando es un nombre. ¿Cuántos sentidos tiene? Buscar relaciones entre ellos:
 - a. Buscar los hiperónimos
 - b. Buscar los hipónimos

Un hipónimo concreta el significado de su hiperónimo, de esta manera “mesa” es más específico que “mueble” y “escritorio” es un tipo particular de “mesa”.

4. Se puede calcular la similitud semántica entre dos *synsets*. WordNet tiene varias medidas de similitud semántica disponibles:
 - a. Medidas basadas en *path*, donde se mide la longitud que hay en el camino que lleva de un concepto a otro y cuánto más corto sea el camino, más similares serán.
 - b. Medidas basadas en el contenido, de forma que cuanta más información comparten dos conceptos, más similares serán.

- c. Medidas basadas en características comunes que pueden compartir los conceptos, y cuántas más características comunes tengan, más similares son.
- d. Medidas híbridas, que combinan todas las anteriores.

En el ejercicio lo que se pide es coger diferentes conceptos y mostrar la similitud entre ellos, utilizando diferentes medidas. Ejemplos de conceptos para los que se quiere medir su similitud:

dog – cat

vehicle – car

dog – car

whale - eagle

Lo razonable es medir la similitud semántica entre sentidos concretos de estas palabras, podría ser el primer sentido del listado que se obtiene, que suele coincidir con el más frecuente.

5. Dada la palabra “watch”, buscar los *synsets* en WordNet y mostrar la definición y las frases de ejemplo.

¿Cómo identificar de qué categoría gramatical es cada *synset* obtenido?

6. Se quiere hacer desambiguación del sentido de una palabra. Una estrategia muy simple (y poco precisa) para desambiguar palabras consiste en seleccionar un *synset* de WordNet al azar sin tener en cuenta el contexto en el que se encuentra la palabra a analizar. Aunque esta estrategia no es de mucha utilidad en la práctica, permite comprender la importancia de utilizar métodos más sofisticados.

Se pide desambiguar la palabra “watch” en la frase “You must watch this film”, seleccionando para ello el primer *synset* identificado por WordNet. Muestra la definición del *synset*. ¿Es la acepción correcta de la palabra?

7. En muchas ocasiones, el significado de una palabra polisémica puede determinarse a partir de su categoría gramatical. Por ejemplo, la palabra “watch” adquiere distintas acepciones dependiendo de si funciona como verbo o sustantivo.

En este ejercicio, se pide desambiguar la palabra “watch” en función de la categoría gramatical que presenta en dos frases diferentes. Específicamente se pide:

- Identificar la categoría gramatical de la palabra “watch” dentro de las frases “*You must watch this film*” y “*He gave me a watch as a present*”.
 - A partir de la categoría gramatical, seleccionar el primer *synset* obtenido en WordNet.
 - Observar el resto de *synsets* que Wordnet proporciona al especificar la categoría gramatical. ¿Ha mejorado la búsqueda de la acepción correcta? ¿Es suficiente?
8. Lo más razonable a la hora de desambiguar el sentido de las palabras es tener en cuenta el contexto en el que se encuentran. Uno de los primeros algoritmos desarrollados para abordar este problema es el algoritmo de Lesk. Dada una palabra polisémica y el contexto en el que aparece, el algoritmo de Lesk devuelve el *synset* con el mayor número de palabras coincidentes entre la frase en la que se encuentra la palabra a desambiguar y las distintas definiciones de los *synsets* que puede poseer una palabra.

- Se pide usar el algoritmo de Lesk para desambiguar la palabra “bank” en las frases “*I went to the bank to deposit my money*” y “*The land along the river bank has vegetation*”. Muestra la definición del *synset*. ¿Son las acepciones correctas de la palabra?

Nota: <https://www.nltk.org/howto/wsd.html>

- Con el paso del tiempo se han ido proponiendo mejoras en el algoritmo original desarrollado por Lesk. Algunas de estas mejoras no solo consideran las definiciones de los *synsets* proporcionados por *WordNet*, sino también sus hiperónimos, hipónimos y frases de ejemplo, proporcionando un mayor contexto con el que comparar.

Se pide Utiliza algoritmos derivados de Lesk para, nuevamente, desambiguar la palabra “bank” en las mismas frases del apartado anterior. Muestra la definición del *synset*. ¿Son las acepciones correctas de la palabra?

Nota: Usar los métodos `simple_lesk()` / `adapted_lesk()` de la librería `pywsd` (<https://github.com/alvations/pywsd>).