

Procesamiento del Lenguaje Natural I

TEMA 2. ANÁLISIS TEXTUAL Y RECURSOS LINGÜÍSTICOS (I)

Soto Montalvo Herranz

Objetivos

- Introducir el problema de la ambigüedad del lenguaje natural.
- Ver los diferentes niveles de análisis del lenguaje.
- Revisar los diferentes recursos lingüísticos que se usan frecuentemente en PLN.

Índice

- Introducción.
- El problema de la ambigüedad.
- Niveles básicos de procesamiento.
- Recursos lingüísticos: Lexicones, diccionarios, ontologías, corpus.

Introducción



Imagen: istockphoto




Imagen: freepik

Ironía
Sarcasmo
Diferentes interpretaciones
Ambigüedad

Dificultades




Mala escritura

Errores ortográficos

Jergas

...



RETO

Imagen: <https://revolveai.com/natural-language-processing-techniques/#>

El problema de la ambigüedad

DRAE

ambiguo, gua

Artículo

Del lat. *ambiguus*.

Sinónimos o afines

Antónimos u opuestos

1. **adj.** Dicho especialmente del lenguaje: Que puede entenderse de varios modos o admitir distintas interpretaciones y dar, por consiguiente, motivo a dudas, incertidumbre o confusión.

SIN.: **confuso**, **equivoco**, **anfibológico**.

ANT.: **claro**, **preciso**.

2. **adj.** Dicho de una persona: Que, con sus palabras o comportamiento, vela o no define claramente sus actitudes u opiniones.

SIN.: **oscuro**, **misterioso**.

ANT.: **claro**, **preciso**.

3. **adj.** Incierto, dudoso.

SIN.: **incierto**, **indeterminado**, **dudoso**.

ANT.: **claro**, **preciso**.

El problema de la ambigüedad

- Podemos ver la ambigüedad como la capacidad de ser entendido de más de una forma. Hay diferentes tipos:
 - Ambigüedad léxica: una palabra varios significados

“Me encontré a Juan en el banco.”

- Ambigüedad sintáctica: una frase se analiza de diferentes formas

“El profesor vio a una mujer con un telescopio.”

El problema de la ambigüedad

- Podemos ver la ambigüedad como la capacidad de ser entendido de más de una forma. Hay diferentes tipos:
 - Ambigüedad semántica: el significado de las palabras puede ser malinterpretado

“El pavo está listo para comer.”

- Ambigüedad anafórica: cuando se usan entidades anafóricas que solo se pueden resolver con el contexto.

“Alex vio a Juan mientras él andaba en bici.”

El problema de la ambigüedad

- Podemos ver la ambigüedad como la capacidad de ser entendido de más de una forma. Hay diferentes tipos:
 - Ambigüedad pragmática: el contexto de una frase da lugar a múltiples interpretaciones.



“Golpeó el armario con el bastón y lo rompió.”

Ejemplo extraído de
archiletras.com



Niveles básicos de procesamiento

- Existen diferentes niveles de análisis para poder comprender y trabajar con el lenguaje humano.



Niveles básicos de procesamiento

- **Análisis fonológico.** Se trata la pronunciación.
- **Análisis morfológico.** Se centra en la identificación de morfemas, las unidades más pequeñas de una palabra que transmiten un significado y no pueden dividirse más.
 - Ejemplos:

Undesirableness -> tres morfemas (prefijo “un”, sufijo “ness” y la raíz “desirable”)

cats -> cat + N + PL (etiquetado morfosintáctico)

Análisis léxico

- El léxico de una lengua es el conjunto de palabras de un idioma (colección de lexemas).
- Un lexema es una unidad básica de significado léxico, una unidad abstracta de análisis morfológico que representa el conjunto de formas o «sentidos» que adopta un único morfema.
- Un analizador léxico encuentra la relación entre los diferentes morfemas de una palabra y convierte la palabra en su forma raíz.
- Un analizador léxico también asigna la posible parte del discurso (PoS, *Part of Speech*) a la palabra.
 - Las palabras pueden clasificarse en clases/categorías (PoS) en base a su función dentro de las frases del lenguaje.

Análisis léxico

- **Tokenización**

- Consiste en dividir un texto en unidades mínimas significativas llamadas “tokens”.

Texto: “El PLN es imprescindible hoy.”

Tokens: [“El”, “PLN”, “es”, “imprescindible”, “hoy”, “.”]

- **Stemming y Lematización**

- Técnicas fundamentales en PLN
 - Se utilizan para reducir las palabras a su forma raíz.
 - Son esenciales para normalizar el texto.

Análisis léxico

- **Stemming**

- Técnica que reduce la palabra a su raíz o *stem*.
- Corta los sufijos de las palabras para reducirlas a su raíz morfológica.
- Ayuda a homogeneizar las diferentes variaciones de una palabra.
- OJO, la raíz que se obtiene no siempre tiene significado:
 - “corriendo”, “corre”, “corrí” -> “corr” (*stem*)
- Algoritmos más utilizados:
 - Algoritmo de Porter
 - Algoritmo de Snowball

Análisis léxico

- **Lematización**

- Segmentación de una palabra para separar la raíz (lexema) de los morfemas de flexión.
- Se obtiene el lema o forma canónica de las palabras.
- Lema: forma de citación de una palabra, la forma que tienen las palabras cuando se buscan en el diccionario.
- Ejemplos:
 - Corriendo, corre, corrí -> correr (lema)
- Considera el contexto y reglas gramaticales para obtener la forma canónica.
- Utiliza un diccionario para lematizar.

Análisis léxico

- **Lematización**

"La lematización suele referirse a hacer las cosas bien con el uso de un vocabulario y el análisis morfológico de las palabras, normalmente con el objetivo de eliminar sólo las terminaciones flexivas y devolver la forma base o de diccionario de una palabra, que se conoce como lema"

(Fuente: [Grupo PNL de Stanford](#))

- **Lematización vs. Stemming**

- Stemming es más rápido, pero menos preciso.
- Lemmatización más lenta, pero más precisa y mejor comprensión del texto

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**
 - Cada token es etiquetado con su categoría gramatical (sustantivo, verbo, adjetivo, etc.).


Texto: “El PLN es imprescindible hoy.”

Tokens: [(El, determinante), (PLN, sustantivo), (es, verbo), (imprescindible, adjetivo), (hoy, adverbio)]

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**

- Clases de palabras:
 - Clases cerradas: número fijo de palabras (preposiciones, pronombres, etc.)
 - Clases abiertas: permiten añadir nuevas palabras (nombres, adjetivos, verbos, etc.)
- Dentro de una clase pueden existir subclases:



Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**
 - Existe un conjunto de etiquetas posibles (PoS tags)
 - Cada etiqueta codifica:
 - Categoría léxica (clase de palabra)
 - Información de los rasgos gramaticales (género, número, etc.)
- No existe un conjunto de etiquetas único. La información codificada depende del lenguaje y del tipo de aplicación.

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**

- Universal POS tags

(<https://universaldependencies.org/u/pos/index.html>)

Open class words	Closed class words	Other
<u>ADJ</u>	<u>ADP</u>	<u>PUNCT</u>
<u>ADV</u>	<u>AUX</u>	<u>SYM</u>
<u>INTJ</u>	<u>CCONJ</u>	<u>X</u>
<u>NOUN</u>	<u>DET</u>	
<u>PROPN</u>	<u>NUM</u>	
<u>VERB</u>	<u>PART</u>	
	<u>PRON</u>	
	<u>SCONJ</u>	

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging) - Tagsets**

- Conjunto de etiquetas del Penn Treebank Project

(https://www.ling.upenn.edu/courses/Fall_2003/ling001/penn_treebank_pos.html)

Tag	Description	Example	Tag	Description	Example
CC	coordin. conjunction	<i>and, but, or</i>	SYM	symbol	<i>+, %, &</i>
CD	cardinal number	<i>one, two, three</i>	TO	“to”	<i>to</i>
DT	determiner	<i>a, the</i>	UH	interjection	<i>ah, oops</i>
EX	existential ‘there’	<i>there</i>	VB	verb, base form	<i>eat</i>
FW	foreign word	<i>mea culpa</i>	VBD	verb, past tense	<i>ate</i>
IN	preposition/sub-conj	<i>of, in, by</i>	VBG	verb, gerund	<i>eating</i>
JJ	adjective	<i>yellow</i>	VCN	verb, past participle	<i>eaten</i>
JJR	adj., comparative	<i>bigger</i>	VBP	verb, non-3sg pres	<i>eat</i>
JJS	adj., superlative	<i>wildest</i>	VBZ	verb, 3sg pres	<i>eats</i>
LS	list item marker	<i>1, 2, One</i>	WDT	wh-determiner	<i>which, that</i>
MD	modal	<i>can, should</i>	WP	wh-pronoun	<i>what, who</i>
NN	noun, sing. or mass	<i>llama</i>	WP\$	possessive wh-	<i>whose</i>
NNS	noun, plural	<i>llamas</i>	WRB	wh-adverb	<i>how, where</i>
NNP	proper noun, singular	<i>IBM</i>	\$	dollar sign	<i>\$</i>
NNPS	proper noun, plural	<i>Carolinas</i>	#	pound sign	<i>#</i>
PDT	predeterminer	<i>all, both</i>	“	left quote	<i>‘ or “</i>
POS	possessive ending	<i>’s</i>	”	right quote	<i>’ or ”</i>
PRP	personal pronoun	<i>I, you, he</i>	(	left parenthesis	<i>[, (, {, <</i>
PRP\$	possessive pronoun	<i>your, one’s</i>	)	right parenthesis	<i>],), }, ></i>
RB	adverb	<i>quickly, never</i>	,	comma	<i>,</i>
RBR	adverb, comparative	<i>faster</i>	.	sentence-final punc	<i>. ! ?</i>
RBS	adverb, superlative	<i>fastest</i>	:	mid-sentence punc	<i>: ; ... --</i>
RP	particle	<i>up, off</i>			

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging) - Tagsets**

- EAGLES Tags (<https://freeling-user-manual.readthedocs.io/en/latest/tagsets/#freeling-tagset-description>, <https://www.ilc.cnr.it/EAGLES96/home.html>)


Position	Attribute	Values
0	category	N : <i>noun</i>
1	type	C : <i>common</i> ; P : <i>proper</i>
2	gen	F : <i>f</i> ; M : <i>m</i> ; C : <i>c</i>
3	num	S : <i>s</i> ; P : <i>p</i> ; N : <i>n</i>

Ejemplo:

NCMS – Nombre común,
masculino y singular.

Análisis léxico

- Etiquetado de las partes del discurso (PoS tagging) – Arquitectura básica



Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**
 - Etiquetado: proceso de asignar etiquetas a las palabras de un texto

tagger $f : W \longrightarrow T = f(W)$

$W = w_1 w_2 \dots w_n$ cadena de palabras (i.e. texto a etiquetar)

$T = t_1 t_2 \dots t_n$ cadena de etiquetas

Yo	bajo	con	el	hombre	bajo	a	tocar	el	bajo	bajo	la	escalera
PPers	Verb	Prep	Det	NCom	Adj	Prep	Verb	Det	NCom	Prep	Det	NCom

Análisis léxico

- **Etiquetado de las partes del discurso (PoS tagging)**

- Etiquetado: proceso de asignar etiquetas a las palabras de un texto
- Problema: una misma palabra puede tener varios tags candidatos (**ambigüedad**)

Yo	bajo	con	el	hombre	bajo	a	tocar	el	bajo	bajo	la	escalera
PPers	Verb	Prep	Det	NCom	Verb	Prep	Verb	Det	Verb	Verb	Det	NCom
	Adj				Adj				Adj	Adj		
	Ncom				NCom				NCom	NCom		
	Prep				Prep				Prep	Prep		

- ¿Cómo resolver la ambigüedad? Desambiguación morfosintáctica.
 - El contexto da información acerca de la categoría concreta de esa palabra en ese momento.

Análisis léxico

- **Recursos en la Web**

- Grampal, procesador morfológico para español:
<http://cartago.llf.uam.es/grampal/grampal.cgi>

GrampalAnálisis de: palabras

Palabra :

bancos

categoría **N** *lema* **BANCO** *género* **masculino** *número* **plural**

Oración : Hoy es doce de enero y hace un estupendo día de sol

Etiqueta (Se utilizará la tabla léxica)

Hoy es doce de enero y hace un estupendo día de sol

Hoy es doce de enero y hace un estupendo día de sol

Hoy	categoría	P	lema	hoy	
es	categoría	V	lema	SER	rasgos singular 3 presente indicativo
doce	categoría	N	lema	DOCE	
de	categoría	PREP	lema	DE	
enero	categoría	N	lema	ENERO	rasgos masculino singular
y	categoría	C	lema	Y	
hace	categoría	V	lema	HACER	rasgos singular 3 presente indicativo
un	categoría	Q	lema	UN	rasgos masculino singular
estupendo	categoría	ADJ	lema	ESTUPENDO	rasgos masculino singular
día	categoría	N	lema	DÍA	rasgos masculino singular
de	categoría	PREP	lema	DE	
sol	categoría	N	lema	SOL	rasgos masculino singular

Oración : Yo bajo con el hombre bajo a tocar el bajo bajo la escalera

Etiqueta

(Se utilizará la tabla léxica

Yo bajo con el hombre bajo a tocar el bajo bajo la escalera

Yo bajo con el hombre bajo a tocar el bajo bajo la escalera

Yo	categoría p	lema yo	rasgos	singular 1
bajo	categoría V	lema BAJAR	rasgos	singular 1 presente indicativo
con	categoría PREP	lema CON		
el	categoría ART	lema EL	rasgos	masculino singular
hombre	categoría N	lema HOMBRE	rasgos	masculino singular
bajo	categoría ADJ	lema BAJO	rasgos	masculino singular
a	categoría PREP	lema A		
tocar	categoría V	lema TOCAR	rasgos	infinitivo
el	categoría ART	lema EL	rasgos	masculino singular
bajo	categoría ADJ	lema BAJO	rasgos	masculino singular
bajo	categoría PREP	lema BAJO		
la	categoría ART	lema EL	rasgos	femenino singular
escalera	categoría N	lema ESCALERA	rasgos	femenino singular

Análisis léxico

- **Recursos en la Web**

- CST's PoS tagger (Brill adaptado): Centre for Language Technology, Univ. of Copenhagen:
http://cst.dk/online/pos_tagger/uk/index.html

CST's Part-Of-Speech tagger (Brill, with adaptations)

The POS-tagger marks each word in a text with information about word class and morphological features, for example

"This page is about the Brill-tagger"

→

This/**DT** page/**NN** is/**VBZ** about/**IN** the/**DT** Brill-tagger/**NNP**

Four active fires in the Los Angeles region have burned over
40,000 acres.

Process my text

Análisis léxico

- **Recursos en la Web**

- Part of Speech Tagging Demo: Cognitive Computation Group, University of Pennsylvania:
https://cogcomp.seas.upenn.edu/page/demo_view/pos

Part of Speech Tagging Demo

4,286 views

If you wish to cite this work, please cite [this publication](#).

Four active fires in the Los Angeles region have burned over 40,000 acres. |

Submit

The Part-of-Speech tagger has automatically labeled the input in the following way.

CD/ Four JJ/ active NNS/ fires IN/ in DT/ the NNP/ Los NNP/ Angeles NN/ region VBP/ have VBN/ burned IN/ over CD/ 40,000
NNS/ acres . / .

Key

Pound sign

\$ Dollar sign

" Close double quote

`` Open double quote

' Close single quote

` Open single quote

, Comma

. Final punctuation

: Colon, semi-colon

-LRB- Left bracket

-RRB- Right bracket

CC Coordinating conjunction

CD Cardinal number

DT Determiner

EX Existential there

FW Foreign word


IN Preposition

JJ Adjective

EJERCICIOS

Análisis sintáctico

- Estudia cómo las palabras se relacionan y combinan entre sí para formar unidades superiores, es decir, se estudia la estructura de una frase agrupando las palabras según su funcionalidad.

- Nivel fonológico → sonido
 - Nivel morfo-léxico → palabra
 - Nivel sintáctico → sintagma
 - Nivel semántico → significado*
 - Nivel pragmático → texto
- 
- Niveles de Representación Lingüística

- Estudia cómo se combinan las palabras en sintagmas y frases.

Análisis sintáctico

- Hay diferentes formas de agrupación:
 - Sintagmas nominales: un nombre con o sin determinante
 - Sintagmas preposicionales: una preposición junto con un sintagma nominal
 - Sintagmas verbales: un verbo que indica una acción, junto con otros sintagmas nominales o preposicionales
 - ...
- Valor de la sintaxis

Rugió mundo el fue volcán y el evacuado (palabras)



El volcán rugió y todo el mundo fue evacuado (orden de sintagmas)

Análisis sintáctico

- ¿Necesidad?
 - Para establecer el sentido de una oración hay que conocer el sentido de cada palabra y, además, la relación jerárquica (sintáctica) entre las palabras que forman la oración.
 - Se forma una estructura en árbol de palabras y relaciones, un árbol sintáctico que representa la estructura de constituyentes de una frase.
 - Para analizar la estructura de una frase se utiliza una gramática.
 - Parser – herramienta que realiza el análisis sintáctico automático. Necesita una gramática del lenguaje y la información morfológica de las palabras.

Análisis sintáctico

- Los algoritmos que llevan a cabo un análisis sintáctico global o análisis sintáctico completo (*full parsing*) proporcionan la estructura de una oración cuando ésta pertenece al lenguaje definido por una gramática.
 - Problema: necesidad de una gramática de amplia cobertura para recoger todas las estructuras del lenguaje. Definir estas gramáticas es muy costoso.
- La salida de un analizador global es un árbol completo de análisis.
- Ambigüedad sintáctica: una oración puede tener varios análisis sintácticos.
- A mayor cobertura de la gramática, mayor es la ambigüedad que produce.

Análisis sintáctico

- Gramática G que define el lenguaje:

$G = \{N, \Sigma, P, S\}$ donde


- $N \equiv$ conjunto de símbolos no terminales
- $\Sigma \equiv$ conjunto de símbolos terminales
- $P \equiv$ conjunto de reglas
- $S \equiv$ símbolo raíz

Ej. Gramática (sencilla) oraciones SUJ-V-OBJ:

$S \rightarrow NP \ VP$
 $NP \rightarrow det \ nombre$
 $VP \rightarrow verbo \ NP$

Análisis sintáctico

- *Treebank*. Cada palabra aparece acompañada de su etiqueta y cada frase es analizada sintácticamente al completo



```
((S
  (NP-SBJ (DT That)
    (JJ cold) (, ,)
    (JJ empty) (NN sky) )
  (VP (VBD was)
    (ADJP-PRD (JJ full)
      (PP (IN of)
        (NP (NN fire)
          (CC and)
          (NN light) ))))
  (. .) ))
```

Análisis sintáctico

- Ejemplo de análisis global para la frase

<https://nlp.lsi.upc.edu/freeling/demo/demo.php>

FreeLing 4.2 - An Open-Source Suite of Language Analyzers
Enjoy the FreeLing!

Write your sentences

Luis ve al hombre con el telescopio.

Analysis options

☐ Number recognition

☐ Date/Time recognition

☐ Quantities, ratios, and percentages

☐ Named Entity Recognition

☐ Multiword detection

☐ Phonetic encoding

☒ No sense annotation

☐ WN sense annotation: All senses

☐ WN sense annotation: [UKB](#) disambiguation

Select language

Auto-detect ▾


Select output

Full Parsing ▾

Submit

Sentence 1

Luis **ve** **a** **el** **hombre** **con** **el** **telescopio** **.**
 luis ver a el hombre con el telescopio .
 NCMS000 VMIP3S0 SP DA0MS0 NCMS000 SP DA0MS0 NCMS000 Fp



Análisis sintáctico

- Problemas del análisis sintáctico completo/clásico (*full parsing*)
 - Requiere conocimiento/recursos lingüísticos complejos (gramáticas, *treebanks*)
 - Escasa cobertura de las gramáticas
 - Escasa robustez
 - Alto coste
- ¿Necesitamos siempre la estructura completa al hacer el análisis sintáctico?
- Análisis sintáctico superficial (*shallow parsing, chunking*)
 - Representación “superficial” de la estructura sintáctica del texto
 - Menores requerimientos
 - Mayor robustez
 - Bajo coste

Análisis sintáctico superficial (*shallow parsing*)

- Divide el texto en segmentos no solapados que se corresponden con estructuras sintácticas no recursivas, también llamadas *chunks*.
- **Chunk:** grupo de palabras (segmento) que funcionan conjuntamente como una única palabra con contenido.

Nombre: funciona a modo de frase/grupo nominal (NP)
Adjetivo: a modo de frase/grupo adjetival (AP)
Verbo: a modo de frase/grupo verbal (VP)
Preposición*: a modo de frase/grupo preposicional (PP)

He reckons the current account deficit will narrow to
NP VP NP VP PP
only #1.8 billion in September.
NP PP NP


- Los *chunk* no son frases en sentido estricto, son aproximaciones.

Análisis sintáctico superficial (*shallow parsing*)

- Los *chunks* son regiones no solapadas en el texto:
[I] saw [a tall man] in [the park].
- Los *chunks* no son estructuras recursivas (un *chunk* no puede contener otros *chunks*)
 - Se simplifica el proceso de detección
 - La recursividad significa que un componente puede estar formado por componentes de su misma categoría
 - Ej. SN = Nombre + Preposición + Nombre (“Coche de caballos”)
- Los *chunks* no son exhaustivos
 - No todas las palabras de una frase tienen que estar incluidas en *chunks*.

Análisis sintáctico superficial (*shallow parsing*)

- Un proceso de *chunking* implica:
 - Localizar el segmento/grupo de palabras.
 - Identificar su clase.



Source: NLTK.org

Análisis sintáctico superficial (*shallow parsing*)

- Gramática para *chunking*
 - Reglas para guiar cómo se deben de identificar los *chunks* en las frases.
 - Las reglas utilizan patrones de etiquetas de PoS, similares a como son los patrones en expresiones regulares.
 - Ejemplo:
 - Identificar un sintagma que puede tener o no un determinante, tener uno o varios adjetivos y un nombre.

<DT>?<JJ>*<NN>

Name of symbol	Description
.	Any character except new line
*	Match 0 or more repetitions
?	Match 0 or 1 repetitions

Análisis sintáctico superficial (*shallow parsing*)

- Gramática para *chunking*

```
text = "Rwanda is set to become the first African nation to host the event from 21-28 September."  
tokens = nltk.word_tokenize(text)  
print(tokens)  
tag = nltk.pos_tag(tokens)  
print(tag)  
gram = ("NP: {<DT>?<JJ>*<NN>}")  
cp = nltk.RegexpParser(gram)  
result = cp.parse(tag)  
print(result)
```

Análisis sintáctico superficial (*shallow parsing*)

```
['Rwanda', 'is', 'set', 'to', 'become', 'the', 'first', 'African', 'nation', 'to', 'host', 'the', 'event', 'from', '21-28',  
'September', '.']  
[('Rwanda', 'NNP'), ('is', 'VBZ'), ('set', 'VBN'), ('to', 'TO'), ('become', 'VB'), ('the', 'DT'), ('first', 'JJ'), ('Africa  
n', 'JJ'), ('nation', 'NN'), ('to', 'TO'), ('host', 'VB'), ('the', 'DT'), ('event', 'NN'), ('from', 'IN'), ('21-28', 'JJ'),  
( 'September', 'NNP'), ('.', '.')]  
(S  
  Rwanda/NNP  
  is/VBZ  
  set/VBN  
  to/TO  
  become/VB  
  (NP the/DT first/JJ African/JJ nation/NN)  
  to/TO  
  host/VB  
  (NP the/DT event/NN)  
  from/IN  
  21-28/JJ  
  September/NNP  
  ./.)
```

Análisis sintáctico superficial (*shallow parsing*)

- Dos enfoques posibles (viéndolo como un proceso de etiquetación):
 - Etiquetando palabras (IOB Tagging).
 - Etiquetando separaciones entre palabras (parentización).

W	e		s	a	w		t	h	e		y	e	l	l	o	w		d	o	g
PRP			VBD			DT			JJ							NN				
B-NP			O			B-NP			I-NP							I-NP				

Source:NLTK.org

Análisis sintáctico superficial (*shallow parsing*)

- *Chunking* etiquetando palabras (IOB Tagging):

- Se etiquetan las palabras por medio de tags
- *Chunk* tags indican el comienzo del *chunk*, las palabras que contiene y el tipo de *chunk* (NP, VP, PP, etc.)

- Etiquetas IOB:

B (*Beginning*): si es la palabra inicial del *chunk*
I (*Internal*): si está en el interior del *chunk*
O (*Outside*): si está fuera del *chunk*

The	morning	flight	from	Denver	has	arrived
B_NP	I_NP	I_NP	B_PP	B_NP	B_VP	I_VP
B_NP	I_NP	I_NP	O	B_NP	O	O

[_{NP} The morning flight] from [_{NP} Denver] has arrived.

Análisis sintáctico superficial (*shallow parsing*)

- *Chunking* etiquetando la separación de palabras:
 - Se etiquetan la separación entre palabras
 - Los tags indican los límites y el tipo del *chunk*

Beginning	End	Between	No bracket (outside)	No bracket (inside)
[NP	NP]	NP] [NP	Out	In

[NP The_{In} morning_{In} flight_{NP}] from [NP Denver_{NP}] has_{Out} arrived.
[NP The morning flight] from [NP Denver] has arrived.

Análisis sintáctico superficial (*shallow parsing*)

https://cogcomp.seas.upenn.edu/page/demo_view/ShallowParse

Shallow Parsing Demo

2,144 views

If you wish to cite this work, please cite [this publication](#).

About This Demo

The benefits of walking backwards.
During the 19th Century, the activity of "retro-walking" was little more than an eccentric hobby, but today research is revealing it can have real benefits for your health and brain.

Submit

The Shallow Parser's output has produced the following parse.

[NP The benefits] [PP of] [VP walking] [ADVP backwards] .
[PP During] [NP the 19th Century] , [NP the activity] [PP of] "[NP retro-walking] [VP was] [ADJP little more] [PP than] [NP an eccentric hobby] , but [NP today research] [VP is revealing] [NP it] [VP can have] [NP real benefits] [PP for] [NP your health and brain] .

Key	
NP	Noun Phrase
VP	Verb Phrase
PP	Prepositional Phrase
ADVP	Adverb Phrase
SBAR	Clause introduced by subordinating conjunction

Análisis sintáctico superficial (*shallow parsing*)

- La técnica de chunking se utiliza también para identificar Entidades Nombradas.
 - Entidad Nombrada (*Named Entity*). Unidad de información fundamental que se refiere a nombres propios que pueden ser clasificados en unas determinadas categorías (Personas, Localizaciones, Organizaciones, etc.)

```
import nltk

nltk.download('maxent_ne_chunker')

text="Santorini earthquakes: What is causing 'unusual' seismic activity and what is the advice for tourists visiting Greece?."
tokens = nltk.word_tokenize(text)
tags=nltk.pos_tag(tokens)
ner_tags = nltk.ne_chunk(tags)
print(ner_tags)
```

Análisis sintáctico superficial (*shallow parsing*)

"Santorini earthquakes: What is causing 'unusual' seismic activity and what is the advice for tourists visiting Greece?."

```
(S
  (GPE Santorini/NNP)
  earthquakes/NNS
  ::
  What/WP
  is/VBZ
  causing/VBG
  'unusual/JJ
  '/'
  seismic/JJ
  activity/NN
  and/CC
  what/WP
  is/VBZ
  the/DT
  advice/NN
  for/IN
  tourists/NNS
  visiting/VBG
  (GPE Greece/NNP)
  ?/.
  ./.)
```

Análisis sintáctico superficial (*shallow parsing*)

- *Chink* es lo opuesto a *chunk*. Es una secuencia de tokens que no están incluidos en un *chunk*.
- Para indicar el chink se ponen los tags fuera de llaves ({ })

```
grammar = r"""
NP:
    {<.*>+}      # Chunk everything
    }<VBD|IN>+{   # Chink sequences of VBD and IN
"""
sentence = [("the", "DT"), ("little", "JJ"), ("yellow", "JJ"),
            ("dog", "NN"), ("barked", "VBD"), ("at", "IN"), ("the", "DT"),
            ("cat", "NN")]
cp = nltk.RegexpParser(grammar)
print(cp.parse(sentence))
```

```
(S
  (NP the/DT little/JJ yellow/JJ dog/NN)
  barked/VBD
  at/IN
  (NP the/DT cat/NN))
```

Análisis sintáctico superficial (*shallow parsing*)

- *Chunking* con la librería spaCy

```
doc = nlp("Israel prepara al ejército para evacuar Gaza y exige que España acoga a los palestinos expulsados.")
for chunk in doc.noun_chunks:
    print(chunk)
```

```
Israel
ejército
Gaza
España
los palestinos
```

Análisis sintáctico superficial (*shallow parsing*)

- *Chunking* con la librería spaCy

```
import spacy
from spacy import displacy

# Load the English Language model
nlp = spacy.load('es_core_news_sm')


# Example sentence to parse
sentence = "Israel prepara al ejército para evacuar Gaza y exige que España acoja a palestinos expulsados."

# Parse the sentence using spaCy
doc = nlp(sentence)

# Visualize the dependency tree with default settings
displacy.render(doc, style='dep', jupyter=True)
```

Análisis sintáctico superficial (*shallow parsing*)

- *Chunking* con la librería spaCy



Análisis sintáctico superficial (*shallow parsing*)

- Entidades Nombradas con spaCy

```
doc = nlp("Israel prepara al ejército para evacuar Gaza y exige que España acoga a los palestinos expulsados.")
for e in doc.ents:
    print(e.text, ' ', e.label_, ' ', spacy.explain(e.label_))
```

Israel	LOC	Non-GPE locations, mountain ranges, bodies of water
Gaza	LOC	Non-GPE locations, mountain ranges, bodies of water
España	PER	Named person or family.

EJERCICIOS

Análisis semántico

- Estudia el significado de la frase completa a partir del significado de las palabras y la estructura sintáctica.
 - Extrae el sentido global a partir de sentidos individuales y de relaciones.
- Es el aspecto lingüístico más difícil de procesar.
 - No hay una teoría general del significado que se pueda implementar.
- El significado de la oración está compuesto por el significado de las unidades que componen la oración
 - Principio de Composicionalidad

Análisis semántico

- Principio de Composicionalidad (Richard Montague):
 - *El significado de una expresión compleja es una función del significado de cada una de las unidades simples que la componen y las reglas sintácticas mediante las cuales se combinan (de las relaciones sintácticas que se establecen entre ellas).*
- Problema esencial: ambigüedad en el significado de las palabras.
 - “Pasé delante del banco.”
- En un contexto determinado la ambigüedad se reduce:

mouse1: a mouse controlling a computer system in 1968.

mouse2: a quiet animal like a mouse

(Ejemplo tomado de [Juravsky y Martin 2020](#), cap. 18, pág. 2)

Análisis semántico

- Homonimia: relación que se establece entre dos o más palabras que se escriben o pronuncian igual, pero tienen distintos significados.
 - Bota (zapato) – bota (recipiente)
 - Rallar (desmenuzar) – rayar (hacer rayas)
- Polisemia: una palabra tiene más de un significado
 - Tienda (carpa) – tienda (comercio)
 - Banco (entidad financiera) – banco (asiento)

Análisis semántico

- *Word Sense Disambiguation (WSD)*
 - Proceso de seleccionar de un diccionario el significado apropiado de una palabra en un contexto concreto.
 - Es una tarea tradicional en PLN.
 - Los sistemas de WSD están formados por dos componentes fundamentales: un diccionario y un algoritmo de desambiguación.
- La desambiguación del sentido de una palabra, salvo en casos extremos, no suele ser un problema para los humanos.
- Las máquinas sí necesitan ayuda para desambiguar, incluso en los casos más sencillos.

Análisis semántico

- *Word Sense Disambiguation (WSD)*

I saw a man who is 98 years old and can still walk and tell jokes



Imagen extraída de
[8]

Análisis semántico

- WordNet (<https://wordnet.princeton.edu/>)
 - Recurso léxico muy utilizado en PLN.
 - Base de datos léxica en inglés, múltiples APIs.
 - Es gratuita.

WordNet

- Red de sentidos
 - Cada nodo representa un sentido.
 - Cada sentido se representa mediante el conjunto de palabras sinónimas en un idioma, denominado *synset* (*set of synonyms*).
 - Cada *synset* tiene asociado más información léxica (ID único del sentido, ejemplos de uso, etc.)
 - Las palabras sinónimas del *synset* son intercambiables en un contexto dado

sentidos	palabras (formas)			
	F_1	F_2	...	F_n
S_1	E_{11}	E_{12}		
S_2		E_{22}		
...				
S_m				

sinonimia (synset)

polisemia

Imagen: obtenida de [6]

WordNet

- Entrada en WordNet:
 - Conjunto de sinónimos (*synset*)
 - Definición (*glosa*).
 - Ejemplo: *car* (extraído de [6])

The noun car has 5 senses (first 3 from tagged texts)

1. (598) car, auto, automobile, machine, motorcar -- (a motor vehicle with four wheels; usually propelled by an internal combustion engine; "he needs a car to get to work")

2. (24) car, railcar, railway car, railroad car -- (a wheeled vehicle adapted to the rails of railroad; "three cars had jumped the rails")

3. (1) cable car, car -- (a conveyance for passengers or freight on a cable railway; "they took a cable car to the top of the mountain")

4. car, gondola -- (the compartment that is suspended from an airship and that carries personnel and the cargo and the power plant)

5. car, elevator car -- (where passengers ride up and down; "the car was on the top floor")

WordNet

- WordNet tiene entradas para nombres, verbos, adjetivos y adverbios.

```
from nltk.corpus import wordnet

n_nouns = len(list(wordnet.all_synsets(pos=wordnet.NOUN)))
n_verbs = len(list(wordnet.all_synsets(pos=wordnet.VERB)))
n_adj = len(list(wordnet.all_synsets(pos=wordnet.ADJ)))
n_adv = len(list(wordnet.all_synsets(pos=wordnet.ADV)))

print("What is inside WordNet?")
print("There are {} nouns.".format(n_nouns))
print("There are {} verbs.".format(n_verbs))
print("There are {} adjectives.".format(n_adj))
print("There are {} adverbs.".format(n_adv))
```

```
What is inside WordNet?
There are 82115 nouns.
There are 13767 verbs.
There are 18156 adjectives.
There are 3621 adverbs.
```

WordNet

- No hay que confundir *synset* con lema:
 - Un *synset* está asociado a un significado y se puede representar con diferentes lemas (dog, can, perro, ...)
 - Un lema es una palabra en lenguaje natural => puede tener varios significados.

```
from nltk.corpus import wordnet
word = 'dog'
synsets = wordnet.synsets(word, pos = 'n')
print('The word', word, 'has', len(synsets), 'synsets.')
print('\n')
print(synsets)
```

The word dog has 7 synsets.

```
[Synset('dog.n.01'), Synset('frump.n.01'), Synset('dog.n.03'), Synset('cad.n.01'), Synset('frank.n.02'), Synset('paw1.n.01'), Synset('andiron.n.01')]
```

WordNet

- No hay que confundir *synset* con lema:

Para un determinado sentido se pueden obtener los lemas que lo representan.

```
ex_synset = wordnet.synset('dog.n.01')
for lemma in ex_synset.lemmas():
    print("{} -> {}".format(ex_synset, lemma))
```

```
Synset('dog.n.01') -> Lemma('dog.n.01.dog')
Synset('dog.n.01') -> Lemma('dog.n.01.domestic_dog')
Synset('dog.n.01') -> Lemma('dog.n.01.Canis_familiaris')
```

Para un determinado lema se pueden obtener todos sus posibles sentidos.

```
ex_lemmas = wordnet.lemmas("dog")
for lemma in ex_lemmas:
    print("{} -> {}".format(lemma.name(), lemma.synset()))
```


```
dog -> Synset('dog.n.01')
dog -> Synset('frump.n.01')
dog -> Synset('dog.n.03')
dog -> Synset('cad.n.01')
dog -> Synset('frank.n.02')
dog -> Synset('pawl.n.01')
dog -> Synset('andiron.n.01')
dog -> Synset('chase.v.01')
```

WordNet

- Lo que da forma a la red son las relaciones conceptuales-semánticas y léxicas entre sentidos.
- Relaciones semánticas a nivel de *synset* (no de palabra):
 - Sinonimia: relación semántica de identidad o semejanza de significados.
 - Antonimia: relación semántica de contraste entre dos unidades léxicas en un contexto determinado.
 - Hiperonimia/hiponimia: “ES_UN”
 - Cereales (Hiperónimo) – arroz, avena, cebada (hipónimos)
 - Troponimia: “hiponimia verbal” (un verbo que es un caso particular de otro).
 - “caminar” – “pasear” (pasear es una forma de caminar)
 - Entailment: relación de implicación-causa. Por ejemplo, “roncar” – “dormir”
 - Meronimia/holonimia: “PARTE_DE”
 - Coche (Holónimo) – motor, ruedas, carrocería (merónimos)

WordNet

- Ejemplo de relaciones: *car*



- WordNet era, y aún es, el estándar de facto para la representación del significado de las palabras de un corpus.

EuroWordNet

- WordNet para lenguas europeas (<http://www.ilic.uva.nl/EuroWordNet/>)
- Bases de datos separadas por idioma
- Generalmente de pago

Niveles básicos de procesamiento

- **Análisis pragmático**

- La pragmática es el estudio del lenguaje en uso, es decir, vincula a un contexto y a una situación comunicativa concreta.
- Es uno de los niveles de análisis más complejos porque debe incorporar al análisis semántico la aportación significativa que pueden hacer los participantes, la evolución del discurso o información presupuesta.
- Problema: presencia adverbios o pronombres cuyo significado no está explícito en una frase, sino que depende del contexto. Se extrae su significado a partir de:
 - Descripciones de la situación actual (quién habla, cuándo habla, dónde está)
 - Frases analizadas previamente

Análisis pragmático

- Elementos esenciales que influyen en el significado de una comunicación:
 - Contexto (situacional como contexto cultural en el que se produce el discurso).
 - Intención del hablante, eso es crucial para su interpretación.
 - Inferencias: conclusiones derivadas de lo que se dice, basadas en contexto y en conocimiento previo.
 - Presuposiciones: suposiciones implícitas que le hablante asume que el oyente ya lo sabe.
 - Actos de habla: acciones que realizar el hablante a través del discurso.

EJERCICIOS

Referencias

- [1] Alonso Lascurain, G. Procesamiento del Lenguaje Natural (PLN). 2022. ([Enlace](#))
- [2] Badia, T. (2003). Técnicas de procesamiento del lenguaje. En M. A. Martí (Ed.), Tecnologías del lenguaje. Barcelona: Editorial UOC.
- [3] Martí, M. A. (Ed.). (2003). Tecnologías del lenguaje. Barcelona: Editorial UOC.
- [4] Rosso, J.A. PoS – Tagging. ([Enlace](#))
- [5] Vilares Ferro, J. Conceptos de PLN: Análisis Morfológico y Etiquetación. Extracción y Recuperación de Información. Máster Universitario en Computación. Facultad de Informática. Universidade da Coruña.
- [6] Vilares Ferro, J. Conceptos de PLN: Semántica Léxica. Extracción y Recuperación de Información. Máster Universitario en Computación. Facultad de Informática. Universidade da Coruña.
- [7] Vossen, Piek. WordNet, EuroWordNet and Global WordNet. Revue française de linguistique appliquée, vol. vol. vii, no. 1, 2002, pp. 27-38.
- [8] Daelemans, W y Šuster, S. Computational Semantics. <https://www.clips.uantwerpen.be/cl1718.bak/cl-2017-6.pdf>

Para profundizar más

- Mangado Martínez, J. Un modelo de análisis sintáctico, paso a paso. Contextos educativos, 5 (2002), 41-56. Universidad de la Rioja.
- Xin, Li y Roth, D. Exploring Evidence for Shallow Parsing. Proceedings of the 2001 workshop on Computational Natural Language Learning (ConLL '01), Vol. 7(9), pp. 1-7. 2001. <https://doi.org/10.3115/1117822.1117826>
- Jiménez Cano, J.M. Acercamiento a las Unidades Sintácticas Sintagma y Oración. Revista Electrónica de Estudios Filosóficos, 9. 2005. Universidad de Murcia.
- Jurafsky, D. & Martin, J.H. (2009). Chapter 13: Syntactic Parsing. Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition (2nd ed.). Pearson–Prentice Hall.
- Bird, S. NLTK Tutorial: Chunking (2005). <http://faculty.washington.edu/wlewis2/bird-loper-chunking.pdf>
- Fellbaum, C. WordNet and wordnets. In: Brown, Keith et al. (eds.), Encyclopedia of Language and Linguistics, Second Edition, 2005, Oxford: Elsevier, 665-670.
- Meng, L., Huang, R., y Gu, J. A Review of Semantic Similarity Measures in WordNet. International Journal of Hybrid Information Technology, Vol. 6, No. 1, 2013.