

Procesamiento del Lenguaje Natural I

TEMA 2. ANÁLISIS TEXTUAL Y RECURSOS LINGÜÍSTICOS (II)

Soto Montalvo Herranz

Objetivos

- Introducir el problema de la ambigüedad del lenguaje natural.
- Ver los diferentes niveles de análisis del lenguaje.
- Revisar los diferentes recursos lingüísticos que se usan frecuentemente en PLN.

Índice

- Introducción.
- El problema de la ambigüedad.
- Niveles básicos de procesamiento.
- **Recursos lingüísticos: Lexicones, diccionarios, ontologías, corpus.**

Recursos lingüísticos

- Los recursos lingüísticos cuidadosamente elaborados a mano pueden utilizarse con éxito para mejorar aplicaciones de PLN [1].
- Recurso lingüístico: conjunto de datos y descripciones del habla o de la lengua en un formato legible por el ordenador [3].
- Los recursos lingüísticos ocupan un papel fundamental en la lingüística computacional.
- Los recursos pueden ser monolingües o multilingües.

Recursos lingüísticos

The term language resources refers to a set of speech or language data and descriptions in machine readable form, used e.g. for building, improving or evaluating natural language and speech algorithms or systems, or, as core resources for the software localization and language services industries, for language studies, electronic publishing, international transactions, subject-area specialists and end users.

Examples of language resources are written and spoken corpora, computational lexicons, terminology databases, speech collection and processing, etc. Basic software tools are also important for the acquisition, preparation, collection, management, customization and use of these language resources and other resources.

ELRA. (2008). Definition. Language resources. Paris: ELRA, European Language Resources Association.

Recursos lingüísticos

- Hay diferentes tipos de recursos lingüísticos:
 - Lexicones
 - Corpus
 - Ontologías
 - Bases de datos léxicas
 - Dicionarios
 - Etc.

Lexicón

- Hay diferentes definiciones para lexicón [2]:
 - En sentido general, conjunto de lexemas (palabras y expresiones idiomáticas o frases hechas) de una lengua, que aparecen listados y definidos en un diccionario.
 - En gramática generativa, componente que contiene un listado de los elementos léxicos de una lengua e información sobre sus propiedades estructurales, esto es, especificaciones sintácticas, semánticas y fonológicas.
 - Sistema mental que contiene toda la información que posee un hablante sobre el vocabulario de su lengua. Dicha información abarca no solo el conjunto de elementos léxicos que conoce el hablante, sino también, por ejemplo, datos sobre cómo se pronuncia una palabra, los patrones gramaticales en los que se emplea, y su significado o significados.

Tipos de lexicones

- Lexicones para análisis de sentimientos:
 - Lexicón para análisis de sentimientos creado por el profesor Bing Liu ([enlace](#)). Es una recopilación de palabras con su valor (positivo o negativo). Todo en inglés.
 - [SentiWordNet](#), utiliza *synsets* (grupos de sinónimos de WordNet). Cada *synset* tiene anotaciones, para identificar el grado de valor positivo, negativo o bien de objetividad que contiene cada palabra.
 - [AFINN lexicón](#), lista de términos en inglés con un rango de valores entre -5 (negativo) y +5 (positivo)

SentiWordNet

- Ejemplo de uso:

```
from nltk.corpus import sentiwordnet as swn

happy_synsets = swn.senti_synsets('happy', 'a')
happy_synset_list = list(happy_synsets)

for synset in happy_synset_list:
    print(synset)
```

```
<happy.a.01: PosScore=0.875 NegScore=0.0>
<felicitous.s.02: PosScore=0.75 NegScore=0.0>
<glad.s.02: PosScore=0.5 NegScore=0.0>
<happy.s.04: PosScore=0.125 NegScore=0.0>
```

*SentiWordNet is a lexical resource for opinion mining.
SentiWordNet assigns to each synset of WordNet three
sentiment scores: positivity, negativity, and objectivity.*

Tipos de lexicones

- Lexicón de emoticonos, se suelen utilizar en aplicaciones que tratan de detectar emociones
 - [EmoLex](#). Lista de palabras inglesas y su asociación con emociones básicas.
- Retos de los sistemas que usan lexicones
 - Lagunas léxicas. Una palabra o frase podría no estar incluida en el lexicón.
 - Polisemia y simetría de las palabras.
 - Dominio específico.

EJERCICIOS

Corpus

- ¿Qué es un corpus?

A corpus is a collection of pieces of language that are selected and ordered according to explicit linguistic criteria in order to be used as a sample of the language. Sinclair, J. (1996). Preliminary recommendations on corpus typology. EAGLES Document EAG-TCWG-CTYP/P. May 1996.

A corpus is a collection of pieces of language text in electronic form, selected according to external criteria to represent, as far as possible, a language or language variety as a source of data for linguistic research. Sinclair, J. (2005). Corpus and text - basic principles. En M. Wynne (Ed.), Developing linguistic corpora: A guide to good practice. Oxford: Oxbow Books.

Corpus

- ¿Qué es un corpus?
 - Un corpus es un conjunto de datos y descripciones del lenguaje natural en formato electrónico. Un corpus puede ser escrito u oral. En referencia a los corpus escritos se puede hablar de corpus lingüísticos como un conjunto de textos preparados y adaptados para la investigación lingüística (no cualquier colección de textos constituye un corpus lingüístico).
 - Una colección de textos se considera un corpus cuando es lo suficientemente representativa de la variedad del lenguaje u objeto lingüístico que se quiere estudiar, abarcable para que la investigación pueda llevarse a cabo y además está almacenada en un soporte procesable por un ordenador (McEnery y Wilson, 1996).
 - Corpora en plural.

Tipos de corpus

- Según el origen o naturaleza de los datos:
 - Corpus oral
 - Corpus textual
 - Corpus multimodal
- Según la codificación y anotación:
 - Corpus simple. Un corpus donde no hay ningún tipo de codificación y anotación en los textos que lo componen.
 - Corpus codificado o anotado. Los textos pueden contener anotaciones correspondientes a diferentes análisis del lenguaje.

Tipos de corpus

- Ejemplo de corpus anotado:
 - Se han anotado enfermedades en textos de notas clínicas

1	filename	mark	label	off0	off1	span
2	es-S0210-56912007000900007-3	T1	ENFERMEDAD	164	166	DM
3	es-S0210-56912007000900007-3	T2	ENFERMEDAD	362	376	deshidratación
4	es-S0210-56912007000900007-3	T3	ENFERMEDAD	575	590	hiperamilasemia
5	es-S0210-56912007000900007-3	T4	ENFERMEDAD	715	733	pancreatitis aguda
6	es-S0210-56912007000900007-3	T5	ENFERMEDAD	1402	1459	formación polipoidea sésil
7	es-S0210-56912007000900007-3	T6	ENFERMEDAD	1526	1550	adenoma vellosa de recto
8	es-S0210-56912007000900007-3	T7	ENFERMEDAD	1669	1676	adenoma
9	es-S0210-48062010000100019-3	T1	ENFERMEDAD	43	62	artritis reumatoide
10	es-S0210-48062010000100019-3	T2	ENFERMEDAD	144	160	íleo suboclusivo
11	es-S0210-48062010000100019-3	T3	ENFERMEDAD	366	381	coágulo vesical
12	es-S0210-48062010000100019-3	T4	ENFERMEDAD	759	785	fisura en la pared vesical
13	es-S0210-48062010000100019-3	T5	ENFERMEDAD	1086	1116	alteración hemodinámica sev
14	es-S1139-76322014000100010-1	T1	ENFERMEDAD	2008	2047	apéndice cecal con signos i
15	es-S1139-76322014000100010-1	T2	ENFERMEDAD	1259	1277	cuadro obstructivo
16	es-S1139-76322014000100010-1	T3	ENFERMEDAD	574	587	abdomen agudo

Tipos de corpus

- Ejemplo de corpus anotado:
 - Titulares de noticias anotados con la polaridad del sentimiento para tres entidades específicas (entidad objetivo (empresa donde se aplica el hecho económico), empresas y consumidores)

text	target	target_sentiment	companies_sentiment	consumers_sentiment
Acuerdos comerciales, sinónimo de oportunidades para República Dominicana	Acuerdos comerciales	POS	POS	POS
EDP Renováveis vende unos activos eólicos en Portugal a China Three Gorges por 242 millones	EDP Renováveis	POS	POS	NEU
El petróleo avista los 82 dólares: la demanda gana a la normalidad en Kazajistán y Libia	Petróleo	POS	NEG	NEG

Tipos de corpus

- Según la lengua:
 - Corpus monolingüe. Todos los textos están escritos en la misma lengua.
 - Corpus bilingüe. Los textos del corpus están escritos en dos lenguas diferentes.
 - Corpus multilingüe. Los textos del corpus están escritos en más de dos lenguas.
- Para corpus escritos en más de una lengua:
 - Corpus paralelo: contiene una misma colección de textos en más de una lengua, de manera que si es bilingüe los textos de una lengua son una traducción exacta de los textos de la otra.
 - Corpus comparable. Los textos de una lengua no son traducciones exactas de los textos del resto de lenguas. Simplemente un corpus comparable se compone de textos en diferentes lenguas con una temática similar [4].

Tipos de corpus

- Ejemplo de corpus paralelo:
 - Texto traducido en tres lenguas adicionales

	A	B	C	D
1	Declaración Universal de Derechos Humanos	Universal Declaration of Human Rights	Déclaration universelle des droits de l'homme	Declaração Universal dos Direitos Humanos
2	Adoptada y proclamada por la Asamblea General en su resolución 217 A (III), de 10 de diciembre de 1948			
3	Preámbulo	Preamble	Préambule	Preâmbulo
4	Considerando que la libertad, la justicia y la paz en el mundo tienen por base el reconocimiento de la dignidad intrínseca y de los derechos iguales e inalienables de todos los miembros de la familia humana,	Whereas recognition of the inherent dignity and of the equal and inalienable rights of all members of the human family is the foundation of freedom, justice and peace in the world,	Considérant que la reconnaissance de la dignité inhérente à tous les membres de la famille humaine et de leurs droits égaux et inaliénables constitue le fondement de la liberté, de la justice et de la paix dans le monde,	Considerando que o reconhecimento da dignidade inerente a todos os membros da família humana e dos seus direitos iguais e inalienáveis constitui o fundamento da liberdade, da justiça e da paz no mundo;
5	Considerando que el desconocimiento y el menosprecio de los derechos humanos han originado actos de barbarie ultrajantes para la conciencia de la humanidad; y que se ha proclamado, como la aspiración más elevada del hombre, el advenimiento de un mundo en que los seres humanos, liberados del temor y de la miseria, disfruten de la libertad de palabra y de la libertad de creencias,	Whereas disregard and contempt for human rights have resulted in barbarous acts which have outraged the conscience of mankind, and the advent of a world in which human beings shall enjoy freedom of speech and belief and freedom from fear and want has been proclaimed as the highest aspiration of the common people,	Considérant que la méconnaissance et le mépris des droits de l'homme ont conduit à des actes de barbarie qui révoltent la conscience de l'humanité et que l'avènement d'un monde où les êtres humains seront libres de parler et de croire, libérés de la terreur et de la misère, a été proclamé comme la plus haute aspiration de l'homme,	Considerando que o desconhecimento e o desprezo dos direitos do Homem conduziram a actos de barbárie que revoltam a consciência da Humanidade e que o advento de um mundo em que os seres humanos sejam livres de falar e de crer, libertos do terror e da miséria, foi proclamado como a mais alta inspiração do Homem;
6	Considerando esencial que los derechos humanos sean protegidos por un régimen de Derecho, a fin de que el hombre no se vea compelido al supremo recurso de la rebelión contra la tiranía y la opresión,	Whereas it is essential, if man is not to be compelled to have recourse, as a last resort, to rebellion against tyranny and oppression, that human rights should be protected by the rule of law,	Considérant qu'il est essentiel que les droits de l'homme soient protégés par un régime de droit pour que l'homme ne soit pas contraint, en suprême recours, à la révolte contre la tyrannie et l'oppression,	Considerando que é essencial a proteção dos direitos do Homem através de um regime de direito, para que o Homem não seja compelido, em supremo recurso, à revolta contra a tirania e a opressão;
7	Considerando también esencial promover el desarrollo de relaciones amistosas entre las naciones,	Whereas it is essential to promote the development of friendly relations between nations,	Considérant qu'il est essentiel d'encourager le développement de relations amicales entre nations,	Considerando que é essencial encorajar o desenvolvimento de relações amistosas entre as nações;
8	Considerando que los pueblos de las Naciones Unidas han reafirmado en la Carta su fe en los derechos fundamentales del hombre, en la dignidad y el valor de la persona humana y en la igualdad de	Whereas the peoples of the United Nations have in the Charter reaffirmed their faith in fundamental	Considérant que dans la Charte les peuples des Nations Unies ont proclamé à nouveau leur foi dans les droits fondamentaux de l'homme, dans la dignité et la valeur de la personne humaine, dans l'égalité	Considerando que, na Carta, os povos das Nações Unidas proclamam, de novo, a sua fé nos direitos fundamentais do Homem, na dignidade e no valor da pessoa humana, na igualdade de direitos dos

Tipos de corpus

- Según la especificidad de los textos:
 - Corpus general
 - Corpus especializado
- Otras clasificaciones:
 - Según la cantidad de textos (grande, de referencia, pequeño, ...)
 - Según la accesibilidad (público, privado, de acceso restringido...)

Tipos de corpus

- ¿Qué tener en cuenta a la hora de diseñar un corpus?
 - Representatividad, que sea una muestra representativa.
 - Aspectos legales y licencias.
 - Plataformas para anotar.

Anotación de corpus

- Anotación lingüística
 - Se realizan marcas o anotaciones sobre los textos para describir, analizar o relacionar aspectos concretos.
 - Las anotaciones pueden ser a nivel de palabra, sintagma, frase, texto completo,...
 - En la descripción de un corpus anotado se puede encontrar información de la anotación:
 - Guía de anotación
 - Información de cuántos anotadores, métricas del grado de acuerdo entre ellos, ...
- Un corpus anotado sirve para entrenar, testear y evaluar modelos de aprendizaje automático.

Corpus

- Ejemplos de algunos corpus:
 - Brown corpus
 - Fue el primer corpus general disponible en formato electrónico.
 - Contiene un millón de palabras, y se recopiló en la Universidad de Brown en los años 1963-64.
 - Contiene textos de diferentes géneros (periódicos, académicos, ficción, etc.)
 - Incluido en NLTK (https://www.nltk.org/nltk_data/)
 - Reuters corpus
 - Gran colección de historias publicadas por la agencia Reuters para fines de investigación y desarrollo.
 - Spanish Billion Word Corpus and Embeddings
 - Corpus no anotado en español con casi 1500 millones de palabras, compilado a partir de diferentes corpus y recursos de la web.

Corpus en NLTK

```
import nltk
from nltk.corpus import brown, movie_reviews, reuters

print('Categorías del corpus brown')
print(brown.categories())
print()
print('Categorías del corpus movie_reviews')
print(movie_reviews.categories())
print()
print('Categorías del corpus reuters')
print(reuters.categories())
```

Categorías del corpus brown

['adventure', 'belles_lettres', 'editorial', 'fiction', 'government', 'hobbies', 'humor', 'learned', 'lore', 'mystery', 'news', 'religion', 'reviews', 'romance', 'science_fiction']

Categorías del corpus movie_reviews

['neg', 'pos']

Categorías del corpus reuters

['acq', 'alum', 'barley', 'bop', 'carcass', 'castor-oil', 'cocoa', 'coconut', 'coconut-oil', 'coffee', 'copper', 'copra-cake', 'corn', 'cotton', 'cotton-oil', 'cpi', 'cpu', 'crude', 'dfl', 'dlr', 'dmk', 'earn', 'fuel', 'gas', 'gnp', 'gold', 'grain', 'groundnut', 'groundnut-oil', 'heat', 'hog', 'housing', 'income', 'instal-debt', 'interest', 'ipi', 'iron-steel', 'jet', 'jobs', 'l-cattle', 'lead', 'lei', 'lin-oil', 'livestock', 'lumber', 'meal-feed', 'money-fx', 'money-supply', 'naphtha', 'natural-gas', 'nickel', 'nkr', 'nzdlr', 'oat', 'oilseed', 'orange', 'palladium', 'palm-oil', 'palmkernel', 'pet-chem', 'platinum', 'potato', 'propane', 'rand', 'rape-oil', 'rapeseed', 'reserves', 'retail', 'rice', 'rubber', 'rye', 'ship', 'silver', 'sorghum', 'soy-meal', 'soy-oil', 'soybean', 'strategic-metal', 'sugar', 'sun-meal', 'sun-oil', 'sunseed', 'tea', 'tin', 'trade', 'veg-oil', 'wheat', 'wpi', 'yen', 'zinc']

EJERCICIOS

Ontologías

- Una ontología establece una organización de los conceptos de un dominio, proporciona un medio para representar la información o el conocimiento procesable por una máquina.

An ontology is a database describing the concepts in the world or some domain, some of their properties and how the concepts relate to each other. (Weigand, 1997)

- Es una descripción formal explícita de los conceptos de un dominio.
- Los conceptos se describen a partir de **propiedades** que representan los atributos, características, relaciones y correspondencias entre los conceptos.

Ontologías

- Los documentos describen conceptos que están relacionados entre ellos.
- Las ontologías dan soporte a la web semántica (son lenguajes de la Web Semántica)
- La web semántica añade información semántica a los contenidos de la Web.
 - Para añadir esa capa de significado se utilizan, entre otras cosas, las ontologías.




Imagen obtenida de [8]

Ontologías

- Las relaciones entre los conceptos forman grafos.





Imagen obtenida de [8]

Ontologías

- RDF (Resource Description Framework) es un estándar para representar afirmaciones sobre recursos.
- Formato de las afirmaciones: tripleta SVO (sujeto, verbo y objeto).



Componentes de una ontología

- Clases – conceptos
- Atributos – propiedades (de un concepto)
- Relaciones (entre conceptos)




Imagen obtenida de [6]

Ontología. Conceptos

- Son los nodos de la red
 - Se organizan en taxonomías
 - Relación is-a (hiperonimia/hiponimia)
- Los individuos son las instancias de los conceptos

Conceptos -vs- Realidad

Dia-de-la-semana | Lunes

Horario-de-visita | 16:00-19:00h




Imagen obtenida de [7]

Ontología. Propiedades-atributos

- Definen características de un único concepto.
- Se trata de información concreta.
- Las propiedades pueden tener restricciones que delimitarán las características que las definen (dominio, rango, ...)




Imagen obtenida de [6]

Ontología. Relaciones

- Los axiomas definen reglas de inferencia que serán ciertas para el dominio de la ontología.
- Se pueden establecer varias relaciones entre dos mismos conceptos.




Imagen obtenida de [6]


Ontologías

- Metodología de desarrollo
 - Definir las clases que forman el dominio
 - Organizar las clases en una jerarquía taxonómica
 - Definir las propiedades de cada clase e indicar las restricciones de sus valores
 - Asignar valores a las propiedades para crear instancias
- Lenguajes
 - Hay lenguajes específicos que permiten definir ontologías.
 - El estándar es Web Ontology Language (OWL)

Web Ontology Language

- Lenguaje estándar para crear ontologías en la Web.
- OWL permite definir clases, relaciones entre clases, atributos de clases e instancias de clases.
- Está construido sobre el modelo intercambiable para la Web RDF.
 - Surgió para resolver las limitaciones de RDF

Constructores OWL



OWL Constructor	DL
SubClassOf	$C \sqsubseteq D$
intersectionOf	$C \sqcap D$
unionOf	$C \sqcup D$
complementOf	$\neg C$
oneOf	$\{a_1, a_2, \dots, a_n\}$
someValuesFrom	$\exists R.C$
allValuesFrom	$\forall R.C$
minCardinality	$\geq n.R$
maxCardinality	$\leq n.R$
cardinality	$= n.R$
hasValue	$\exists R.\{a\}$

Imágenes obtenidas de [10]

Ontologías

- Ventajas
 - Organizan la información como cada uno quiera cuando crea la ontología.
 - Ayudan mucho en la desambiguación.
- Desventajas
 - Coste de generación
 - Coste de mantenimiento

Enlaces de interés

- Diferentes conjuntos de datos y recursos de PLN. ([Enlace](#))
- Base de datos léxica de español. ([Enlace](#))

Referencias

- [1] Silberztein, X. Linguistic Resources for Natural Language Processing. On the Necessity of Using Linguistic Methods to Develop NLP Software, Springer, 2024.
- [2] Palacios Martínez, I., Alonso Alonso, R., Cal Varela, M., Calvo Benzies, Y., Fernández Polo, F.X., Gómez García, L., López Rúa, P., Rodríguez Rodríguez, Y., Varela Pérez, J.R. Diccionario electrónico de enseñanza y aprendizaje de lenguas. 2019.
- [3] [ELRA](#). Language Resources Association.
- [4] McEnery, A. y Xiao, Z. Incorporating Corpora: Translation and the Linguist. Translating Europe. Capítulo “Parallel and comparable corpora: What are they up to?” Multilingual Matters. 2007.
- [5] Weigand, H. Multilingual Ontology-Based Lexicon for News Filtering – The TREVI Project. Proceedings of the IJCAI Workshop on Multilingual Ontologies – Nagoya, 1997.

Referencias

- [6] Sogo, J.G. No habrá PLN sin ontologías. ([Enlace](#))
- [7] Segura, A., Sánchez, S., y Prieto, M.E. Aplicaciones de la expansión de consultas en ontologías de dominio a la búsqueda de objetos de aprendizaje en repositorios. 2010.
- [8] Ceriani, M. y Vaisman, A. Ontologías en la Web. Intro a la Web Semántica. ([Enlace](#))
- [9] Martínez, M. M. Introducción a la Web Semántica. Dpto. de Informática. Universidad de Valladolid. ([Enlace](#))
- [10] Motz, R. y Rohrer, E. Ingeniería Ontológica. Facultad de Ingeniería Udelar. ([Enlace](#))

Para profundizar más

- McEnery, T. y Wilson, A. Corpus linguistics. Edinburgh University Press. 1996.
- Llisterri, J. y Martí, M. A. Las tecnologías lingüísticas en la sociedad de la información. En M. A. Martí y J. Llisterri (Eds.), Tratamiento del lenguaje natural. Tecnología de la lengua oral y escrita, pp. 13-28. Edicions de la Universitat de Barcelona - Fundació Duques de Soria, 2002.
- Aldama, N., Guerrero, M., Montoro, H. y Samy, D. Anotación de corpus lingüísticos: metodología utilizada en el Instituto de Ingeniería del Conocimiento (IIC). Whitepaper. Instituto de Ingeniería del Conocimiento.
- García Hernández, E. Aplicación de las ontologías para la representación del conocimiento. ISKO. CAPÍTULO ESPAÑOL. CONGRESO (7º: 2005: BARCELONA), pp. 224-237.
- Béjar, J. Desarrollo de Ontologías. ECSDI, 2024/2025. Facultad de Informática de Barcelona, Universidad Politécnica de Cataluña.