

Procesamiento del Lenguaje Natural I

TEMA 4. REDES NEURONALES EN PLN

Soto Montalvo Herranz

Objetivos

- Repasar el concepto de red neuronal artificial.
- Conocer los fundamentos de las redes convolucionales.
- Saber cómo aplicar redes convolucionales a tareas de PLN.
- Conocer los fundamentos de las redes recurrentes.
- Saber cómo aplicar redes recurrentes a tareas de PLN.

Índice

- Conceptos preliminares
- Redes convolucionales
- Redes convolucionales para PLN
- Redes recurrentes
- Redes recurrentes para PLN
- LSTM
- Bibliografía

Índice

- **Conceptos preliminares**
- Redes convolucionales
- Redes convolucionales para PLN
- Redes recurrentes
- Redes recurrentes para PLN
- LSTM
- Bibliografía

Conceptos preliminares

- La idea de las redes neuronales computacionales se basa en la estructura neuronal del córtex del cerebro humano.




Imagen: Julia Anavel Pintado Cordova. Trabajo propio, CC BY-SA 4.0.

Una neurona biológica es una célula que tiene un cuerpo (donde está el núcleo de la célula) y múltiples ramificaciones.

Tipos de ramificaciones:

- Dendritas, que reciben señales de otras neuronas en forma de mensajes químicos y se transforman en impulsos eléctricos que viajan por las dendritas hasta llegar al cuerpo de la neurona.
- Axón, que es la salida de la neurona y que se conecta con las dendritas de otras neuronas.





Imagen: [2]

Conceptos preliminares

- Si la suma de todos los impulsos eléctricos que llegan al cuerpo de la neurona (la suma de las entradas que llegan desde otras neuronas) alcanza un umbral, se genera un impulso eléctrico que viaja por el axón para llegar a las dendritas de otras neuronas.
- Similitudes entre neurona biológica y una unidad de neurona en las redes neuronales computacionales.



Las dendritas de una neurona se corresponden con las entradas x_n de una unidad de la red.

El axón de una neurona se corresponde con la salida a de la unidad.

El cuerpo de la neurona es la unidad propiamente dicha.

Imagen: Julia Anavel Pintado Cordova. Trabajo propio, CC BY-SA 4.0.

Conceptos preliminares

- Las Redes Neuronales Artificiales (ANN, Artificial Neural Network) son modelos computacionales inspirados en las redes neuronales biológicas del cerebro humano.
- Se utilizan para modelar relaciones complejas entre entradas y salidas y encontrar patrones en los datos.
- La estructura de una red neuronal puede variar, hay modelos muy simples con una sola capa de neuronas y redes complejas con múltiples capas.
- Las redes neuronales se pueden clasificar en diferentes tipos según cómo transmiten los datos desde los nodos de entrada a los nodos de salida:
 - Red neuronal prealimentada
 - Red neuronal de retropropagación

Conceptos preliminares

- **Tipos de redes neuronales. Red neuronal prealimentada (Feedforward)**

- Los datos son procesados en una dirección, desde el nodo de entrada hasta el nodo de salida.
- Flujo de información unidireccional desde la entrada hasta la salida, sin bucles (las conexiones entre las unidades de la red no forman ciclos).
- Perceptrón de Múltiples Capas (MLP) -> múltiples capas de neuronas en una configuración de alimentación directa (feedforward).





Imagen: [2]

Conceptos preliminares

- **Tipos de redes neuronales. Red neuronal de retropropagación.**

- Los valores se transfieren desde el nodo de entrada al de salida tomando diversos caminos de la red.
- La retropropagación es la técnica para entrenar redes de múltiples capas, permitiendo que el error calculado en la salida se propague hacia atrás a través de la red para actualizar eficientemente los pesos en todas las capas.



- El nombre de propagación inversa o retropropagación (*backpropagation*) proviene de que el cálculo comienza optimizando los parámetros desde el final o salida de la red neuronal hacia el principio o entrada de la red.
- Se optimizan los parámetros de una red neuronal mediante una técnica de descenso por gradiente minimizando el error en cada capa.

Conceptos preliminares

- **Tipos de redes neuronales. Red neuronal de retropropagación.**
 - Ventajas: el algoritmo de retropropagación es muy efectivo.
 - Desventajas:
 - Muy dependiente de la inicialización de la red => hay que probar varios escenarios diferentes.
 - Riesgo de desvanecimiento del gradiente => a mayor profundidad en la red, mayor posibilidad de que la señal de error sea pequeña y no se pueda actualizar el valor del peso, parando entonces el entrenamiento.

Conceptos preliminares

- **Tipos de redes neuronales. Otra clasificación por su arquitectura.**
 - Redes Neuronales Simples o prealimentadas.
 - Todos los nodos de una capa están conectados con todos los nodos de la capa siguiente.
 - Solo tiene una capa oculta.
 - Redes con varias capas ocultas (aprendizaje profundo):
 - Redes Neuronales Convolucionales (CNN). Muy utilizadas en procesamiento de imágenes. Tienen tres tipos de capas:
 - Capas convolucionales que extraen la información de los datos de entrada, mediante filtros preconfigurados.
 - Capas de pooling, para reducir la dimensionalidad.
 - Capas densas (fully connected), que combinan todas las características para realizar la predicción final.
 - Redes Neuronales Recurrentes (RNN). Diseñadas para procesar secuencias de datos, como texto, audio o series temporales.
 - Tienen la capacidad de mantener y recordar información pasada utilizando conexiones recurrentes. Esto las hace especialmente adecuadas para aplicaciones en las que el contexto y la secuencia de los datos son importantes.

Conceptos preliminares

- **Tipos de aprendizaje en redes neuronales.** Durante el entrenamiento, la red neuronal emplea diferentes métodos de aprendizaje.
 - Aprendizaje supervisado o controlado. Se le proporciona al sistema los patrones y el resultado que debe generar. De esta manera, la red ejecutará cálculos y combinaciones para que su salida se ajuste a lo que se espera.
 - Aprendizaje no supervisado. No se conoce la salida a generar, por tanto, la red se basa solo en las observaciones realizadas a los valores de entrada.
 - Aprendizaje reforzado. La red ejecuta el análisis por sí misma y va evaluando las salidas. Cada salida correcta se refuerza positivamente, mientras que las salidas erróneas se descartan.
 - Aprendizaje híbrido. Se trata de un método de aprendizaje que combina los mecanismos anteriores.

Índice

- Conceptos preliminares
- **Redes convolucionales**
- Redes convolucionales para PLN
- Redes recurrentes
- Redes recurrentes para PLN
- LSTM
- Bibliografía

Redes convolucionales

- Las redes CNN (Convolutional Neural Network) se propusieron inicialmente para clasificación de imágenes.
 - Idea de partida: algunas partes más pequeñas (filtros) de una imagen pueden servir para identificar lo que la imagen representa.




Imagen: Willy Mobilo (iStock)




Imagen: Wildeside57 (iStock)




Imagen: johan63 (iStock)

- ¿Cómo encontrar los filtros o patrones?

Redes convolucionales

- La entrada de una red CNN es una matriz.
- Hay dos operaciones principales: convolución y pooling.




Imagen: [4]




Imagen: [4]

Operación de convolución:

- Se define el número de filtros y su tamaño. Los filtros son para extraer las características relevantes de los datos de entrada.
- Los valores de un filtro se inicializan de forma aleatoria y se van ajustando durante el entrenamiento.
- Cada filtro se mueve a lo largo de la matriz de entrada, en cada movimiento se calcula un valor (aplicando *element-wise multiplication*)
- Cada filtro, como salida genera una nueva matriz (*feature map*).

Redes convolucionales

- Operación de pooling.
 - Consiste en reducir el tamaño de las representaciones (*feature map*) que se han obtenido con los filtros.
 - Idea: si se transforma la imagen de entrada en una más pequeña, esto no afecta al objeto que representa la imagen.



Imagen: tiero (iStock)



Imagen: tiero (iStock)

- El objetivo es extraer las características más relevantes de la matriz convolucionada (*feature map*).

Redes convolucionales

- Operación de pooling. Tipos.
 - Max-pooling. Se selecciona el valor máximo del mapa de características.




Imagen: [5]

Max pooling using kernel of size 2*2 with stride 2

- Average-pooling. Es la media de los valores del mapa de características.




Imagen: [5]

Max pooling and Average Pooling comparison

Redes convolucionales

- Por último, después de las capas de convolución y pooling, están las capas densas (*fully connected*) que realizan la tarea de clasificación basándose en las características extraídas en las capas anteriores.
 - Estas capas se colocan al final de la arquitectura CNN.
 - En estas capas, cada nodo está conectado con un nodo de la capa anterior.
- Mientras que las capas convolucionales y de agrupación (pooling) utilizan funciones ReLU (para hacer el modelo no lineal), las capas densas utilizan funciones de activación softmax.





Imagen: [6]



Índice

- Conceptos preliminares
- Redes convolucionales
- **Redes convolucionales para PLN**
- Redes recurrentes
- Redes recurrentes para PLN
- LSTM
- Bibliografía

Redes convolucionales para PLN

- De la misma forma que en la imagen existen filtros que nos ayudan a identificar un objeto o clasificar la imagen:




Imagen: Wildside57 (iStock)

- En un texto también hay partes que pueden ayudar a clasificarlo.

*“Este club tiene profesores **muy buenos**, he **mejorado mucho** mi técnica y **me siento con más confianza**. Ahora voy a los partidos con **mucha seguridad** y se nota en los resultados. **Definitivamente seguiré en el club.**”*

Redes convolucionales para PLN

- ¿Cómo usar CNN para PLN?
 - Hay que elegir **un tamaño** que sea representativo de los textos de la colección. Es recomendable elegir un tamaño que se ajuste a la mayoría de los textos de la colección, para no desperdiciar memoria.
 - Entrenamiento:
 - Tokenizar => se aprende el vocabulario (tokens diferentes de la colección de textos de entrenamiento).
 - Por un lado, a cada token se le asocia un índice del vocabulario.
 - Por otro lado, cada token estará representado por un vector de números reales (todos los vectores tendrán la misma dimensión).
 - Inicialización de los vectores: modelo de Word embeddings o inicialización aleatoria.
 - Se aplicará *padding* o *truncation* sobre el texto tokenizado para asegurar que tiene el tamaño de entrada fijado.
 - *Padding*. Se añade el token <pad> (con índice de vocabulario 0) tantas veces como sea necesario para que el texto tenga el tamaño de tokens que se había decidido previamente. Se pueden añadir los tokens <pad> al principio, final o en ambos extremos del texto.
 - *Truncation*. Si el texto tiene un tamaño superior al establecido, hay que eliminar los tokens sobrantes. Se pueden quitar tokens del principio, del final o de ambos extremos.

Redes convolucionales para PLN



- ¿Cómo usar CNN para PLN?
 - ¿Cómo son los filtros en un problema de PLN?
 - Los textos solo tienen una dimensión: el número de tokens => el filtro que se aplica en la capa de convolución se puede ver como **una ventana de tokens**. El tamaño de la ventana es el tamaño del filtro.
 - Se pueden crear los filtros que se quieran de diferentes tamaños.
 - Un filtro de tamaño N, será una matriz de dimensión $N \times \text{dim}$ (donde dim es la dimensión de los vectores de embeddings).
 - Cada filtro se aplica sobre los textos tokenizados.

Índice

- Conceptos preliminares
- Redes convolucionales
- Redes convolucionales para PLN
- **Redes recurrentes**
- Redes recurrentes para PLN
- LSTM
- Bibliografía

Redes recurrentes

- Las Redes Neuronales Recurrentes (RNN, *Recurrent Neural Networks*) están diseñadas para procesar secuencias de datos, como texto, audio o series temporales.
- Son capaces de mantener y recordar información pasada utilizando conexiones recurrentes. La información se retroalimenta a través de bucles en la red.



- Cuando se procesa un dato de la secuencia, cada neurona “se alimenta a sí misma” con su salida, además de recibir nuevas entradas.

Redes recurrentes

- Componentes clave de una RNN:
 - **Bucles de retroalimentación.** Cada neurona tiene un bucle que reintroduce la salida de la neurona en ella misma.
 - **Estados ocultos (*hidden states*).** Actúan como la “memoria” de la red, almacenando información sobre los cálculos anteriores. En la imagen los estados ocultos son $s_1, s_2, \dots, s_4$ (cada elemento mantiene la información del dato anterior en la secuencia).




Imagen: [7]

$$s_t = \phi_1(U x_t + W s_{t-1})$$

$$o_t = \phi_2(V s_t)$$

Donde ϕ_1 y ϕ_2 son funciones de activación, o_t es la salida en el tiempo t y U , V y W son matrices de pesos.




Imagen: [7]

Redes recurrentes


- Funcionamiento de una RNN:
 - **Propagación hacia adelante.** En cada paso de tiempo, la entrada actual y el estado oculto anterior se utilizan para calcular el estado oculto actual.
 - **Retropropagación a Través del Tiempo (BPTT).** Los gradientes se calculan retrocediendo a través de cada paso de tiempo para actualizar los pesos, lo que permite a la red aprender de secuencias de entrada.
- Problemas comunes con las RNN:
 - **Desvanecimiento del gradiente.** En redes muy profundas o con secuencias largas, los gradientes utilizados en el entrenamiento pueden volverse muy pequeños => esto puede impedir que la red aprenda.
 - **Explosión del gradiente.** Opuesto al desvanecimiento, los gradientes pueden crecer exponencialmente => harían que el entrenamiento fuese inestable.

Índice

- Conceptos preliminares
- Redes convolucionales
- Redes convolucionales para PLN
- Redes recurrentes
- **Redes recurrentes para PLN**
- LSTM
- Bibliografía

Redes recurrentes para PLN

- Las RNN son un enfoque habitual para tareas de PLN, por su capacidad para mantener y actualizar el estado interno que captura la información de los estados previos.



- Cada palabra se procesa secuencialmente.
- La información de las palabras anteriores se almacena en un estado oculto.
- El estado oculto se actualiza en cada paso considerando la palabra actual y el estado oculto anterior.

- Entrada de la red: secuencia de palabras, donde cada una se representa con un vector de embeddings.
- A la hora de procesar el texto, cada token se asocia con un número (índice del token en el vocabulario).
- Salida: la red genera una salida en cada paso (predicción de la siguiente palabra en una secuencia, clasificación del texto, o cualquier otra tarea).

Redes recurrentes para PLN

- Se crea una matriz de embeddings de dimensión $|V| \times d$, donde $|V|$ es el tamaño del vocabulario y d la dimensión de los embeddings.
 - Cada fila de la matriz es un embedding de un token del vocabulario. El índice de la fila es el índice del token en el vocabulario.
 - La matriz se puede inicializar de forma aleatoria o a partir de un modelo de Word Embedding.
- La capa de entrada de la red son los embeddings de los tokens.
- La capa de salida utiliza la función softmax para transformar los valores del último estado en probabilidades.

Redes recurrentes para PLN

- Desventajas de las RNN:
 - No pueden procesar correctamente secuencias largas. La red tiende a olvidar la información de las primeras neuronas.
 - Desvanecimiento del gradiente, ocurre cuando el gradiente va tomando valores muy pequeños => los parámetros no se modifican eficazmente.
- Posibles soluciones:
 - LSTM (Long-Short Term Memory Networks), tienen los mismos inconvenientes que las RNN, pero más atenuado. No llegan a eliminar por completo el desvanecimiento del gradiente.
 - Son más robustas que otras redes y se pueden utilizar para una gran variedad de aplicaciones (traducción automática, reconocimiento de voz, análisis de sentimientos, etc.)

Índice

- Conceptos preliminares
- Redes convolucionales
- Redes convolucionales para PLN
- Redes recurrentes
- Redes recurrentes para PLN
- **LSTM**
- Bibliografía

LSTM

- Las LSTM (redes neuronales de memoria a corto plazo) son capaces de aprender contextos mayores.
- Estas redes incluyen unas **celdas o nodos de memoria** que “recuerdan” los datos por largos periodos porque priorizan la información que “les interesa”. Van gestionando las entradas y salidas de los nodos de la red según dicha memoria.




Imagen: [8]

- La celda de memoria se compone de varias puertas principales: puerta de entrada, de salida y puerta de olvido.
- Las puertas permiten controlar la información a retener y la que se debe de olvidar.
- El estado oculto h_t representa la memoria a corto plazo y el estado c_t representa la memoria a largo plazo.

LSTM

- Resumen:




Imagen: [9]

forget gate (puerta de olvido): qué parte de la información del pasado no es importante.

input gate (puerta de entrada): de la información actual, hay algo que sea importante para recordar.

candidate gate (puerta candidata): Si hay algo importante que recordar, cómo se combina con la información del pasado.

output gate (puerta de salida): qué información es importante a corto plazo.

state cell (estado de la celda): guarda el estado de la celda actual.

LSTM

- Una capa con celdas LSTM estaría formada por celdas conectadas unas con otras:




Imagen: [9]

LSTM

- La puerta de entrada (1) es la que decide qué información tiene que ser actualizada en la celda de memoria.
 - Tiene en cuenta la entrada x_t y el estado previo de la celda de memoria (h_{t-1}).
 - Genera un vector de activación que representa la información a añadir => se realiza una operación matemática entre el vector de activación y el estado previo c_{t-1} .




Imagen: [8]

- La puerta de olvido (2) permite que la red LSTM elimine información obsoleta de la celda de memoria.
 - Tiene en cuenta la entrada actual y el estado previo para generar el vector de activación.
 - Se realiza una operación matemática entre este segundo vector de activación y el estado previo c_{t-1} .
- A partir de las dos operaciones previas (puertas de entrada y olvido) se obtiene el estado actual c_t .

LSTM

- La puerta de salida (3) determina la salida de la red LSTM en un momento dado.
 - Utiliza la entrada actual x_t y el estado actual de la celda de memoria c_t para generar un vector de activación que representa la salida => se obtiene h_t .




Imagen: [8]


- La combinación de las tres puertas permite a la red LSTM manejar eficazmente las dependencias a largo plazo.
- Durante la retropropagación del gradiente, la LSTM mantiene un flujo constante de información a través del tiempo.
 - Minimiza el problema del descenso del gradiente.
 - El aprendizaje es más estable y preciso.

LSTM

- Posibles desventajas de las redes LSTM:
 - Son más complejas de entrenar que las redes neuronales tradicionales. Tienen un gran número de hiperparámetros que se tienen que ajustar para obtener buenos resultados.
 - Suelen necesitar ser entrenados con datasets grandes => suelen necesitar mayor potencia de cálculo.
 - Son más sensibles al sobreentrenamiento si los datos de entrenamiento no son suficientemente variados y representativos.
- Se siguen utilizando mucho y hay variantes:
 - Redes LSTM bidireccionales
 - Redes LSTM apiladas
 - Redes LSTM con mecanismos de atención

Bi-LSTM

- En las RNN, la información va pasando de estado a estado, desde el estado inicial hasta el estado final (último token).
- Hay tareas donde puede ser recomendable añadir una capa más para poder leer la secuencia de entrada de derecha a izquierda (desde el último token al primero).
- Las redes LSTM bidireccionales (Bi-LSTM) funcionan procesando los datos de entrada en dos direcciones: desde el inicio hasta el final y desde el final hasta el principio.



Ejemplo: "I Will swim today".

Sentido hacia adelante: "I" en $t=0$, "will" en $t=1$, "swim" en $t=2$ y "today" en $t=3$

Sentido hacia atrás: "today" en $t=0$, "swim" en $t=1$, "will" en $t=2$ y "I" en $t=3$

Bi-LSTM

- Posibles desventajas de las redes LSTM bidireccionales:
 - Necesitan más recursos computacionales y memoria que las RNN estándar (necesitan mantener dos capas de RNN y realizar dos pasadas de la secuencia de entrada).
 - No pueden manejar datos en línea o en streaming (necesitan esperar a que toda la secuencia esté disponible antes de poder comenzar a procesarla).

Índice

- Conceptos preliminares
- Redes convolucionales
- Redes convolucionales para PLN
- Redes recurrentes
- Redes recurrentes para PLN
- LSTM
- **Bibliografía**

Bibliografía

- [1] Alonso Martín, J.A. El desembarco de la inteligencia artificial en la traducción automática. Las redes neuronales y el cerebro humano. El español en el mundo. Anuario 2022. ([Enlace](#))
- [2] Lean Componentes. Tipos de Redes Neuronales y sus Aplicaciones en la Empresa. 2024. ([Enlace](#))
- [3] Segura Bedmar, I. Redes convolucionales para Procesamiento del Lenguaje Natural. Procesamiento de Lenguaje Natural con Aprendizaje Profundo. Máster en Ciencia y Tecnología Informática. UC3M.
- [4] Keita, Z. Introducción a las redes neuronales convolucionales (CNN). 2024. ([Enlace](#))
- [5] Mahajan, P. Max Pooling. 2020. ([Enlace](#))
- [6] Canorea, E. Convolutional Neural Network: Guía para entenderlas. 2024. ([Enlace](#))
- [7] Rivera, M. Introducción a Redes Neuronales Recurrentes (RNN). 2018. ([Enlace](#))
- [8] Datascientest. Memoria a largo plazo a corto plazo (LSTM): ¿Qué es?. 2024. ([Enlace](#))
- [9] Moya, R. Procesamiento del Lenguaje Natural, con Python. Clasificación de textos, redes neuronales, 2021. ([Enlace](#))