

Procesamiento del Lenguaje Natural I

TEMA 5. REPRESENTACIÓN TEXTUAL CON TRANSFORMERS

Soto Montalvo Herranz

Objetivos

- Ver cómo obtener embeddings contextuales de diferentes formas.

Precedentes de representaciones textuales

- **Bolsa de palabras (*Bag-of-Words*)**

- Vectores dispersos (*sparse vectors*)
- Representaciones basadas en frecuencia de términos
- Ignora el contexto y las relaciones semánticas entre términos
- Ejemplos: Pesado Binario, TF-IDF, BM25...

- ***Embeddings* estáticos**

- Vectores densos
- Representaciones fijas por término (no tienen en cuenta el contexto en el que se encuentran)
- Incorporan las relaciones semánticas entre términos
- Ejemplos: Word2Vec, GloVe, FastText...

Embeddings contextuales con Transformers

- Los mecanismos de atención permiten considerar el contexto en el que se encuentran las palabras
 - Obtienen representaciones diferentes en función de las palabras que la rodean.
- Es posible obtener *embeddings* contextuales, considerando tanto la semántica como el contexto de las palabras.




Imagen: [1]

Embeddings contextuales con Encoders

- Los encoders aprenden representaciones profundas de una entrada de texto.
- Son idóneos para la obtención de embeddings contextuales.
 - Una forma habitual de obtenerlos es hacer la media de los *embeddings* de los tokens en la última capa oculta.




Imagen: [2]

Embeddings contextuales con Bi-encoders

Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks

Nils Reimers and Iryna Gurevych
Ubiquitous Knowledge Processing Lab (UKP-TUDA)
Department of Computer Science, Technische Universität Darmstadt
www.ukp.tu-darmstadt.de

Abstract

BERT (Devlin et al., 2018) and RoBERTa (Liu et al., 2019) has set a new state-of-the-art performance on sentence-pair regression tasks like semantic textual similarity (STS). However, BERT uses a cross-encoder: Two

tic similarity comparison, clustering, and information retrieval via semantic search.

BERT set new state-of-the-art performance on various sentence classification and sentence-pair regression tasks. BERT uses a cross-encoder: Two




Imagen: [3]

- Sentence Transformers (SBERT)
 - Embeddings calculados de forma independiente por cada frase.
 - Se puede hacer fine-tuning para otras tareas.

Se extiende el concepto de embedding a la sentencia.

Bibliografía

- [1] Alammam, J. The Illustrated Transformer, 2018. ([Enlace](#))
- [2] Ferrer, J. Cómo funcionan los transformadores: Una exploración detallada de la arquitectura de los transformadores, 2024. ([Enlace](#))
- [3] Reimers, N. y Gurevych, I. Sentence-bert: Sentence embeddings using siamese bert-networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-ICJNLP). 2019. pp 3973–3983 . 10.18653/v1/D19-1410