

Procesamiento del Lenguaje Natural I

TEMA 6. Data Augmentation

Soto Montalvo Herranz

Objetivos

- Introducir el concepto de Data Augmentation (DA).
- Conocer las principales técnicas de DA.
- Conocer las principales librerías que implementan las técnicas de DA.
- Conocer otras formas de aumento de datos sin utilizar librerías específicas.

Índice

- Introducción
- Aumento de datos en PLN
- Algunas librerías para aumento de datos en PLN
- Aumento de datos sin librerías
- Bibliografía

Índice

- **Introducción**
- Aumento de datos en PLN
- Algunas librerías para aumento de datos en PLN
- Aumento de datos sin librerías
- Bibliografía

Introducción

- Data Augmentation (DA) o Aumento de Datos son técnicas dirigidas a crear nuevos datos.
 - Se crean nuevos datos a partir de los datos disponibles.
 - Es necesario aplicar algún tipo de modificación sobre los datos originales para poder generar los nuevos datos.
- El aumento de datos es un proceso automático que ayuda a reducir los costes de creación de nuevos datos.
- Aumento de datos $\neq$ datos sintéticos.

Introducción

- ¿Cuándo utilizar DA?
 - Para que los modelos no sobreajusten.
 - Si el conjunto de entrenamiento inicial es muy pequeño o no está balanceado o no tiene suficiente variación en los datos.
 - Para mejorar la exactitud del modelo.
 - Para reducir el coste operativo del etiquetado.
- Limitaciones del DA
 - Se mantienen los sesgos del conjunto de datos original.
 - Hay que encontrar el enfoque eficaz para cada problema.
 - Garantizar la calidad de los datos aumentados no es fácil.

Índice

- Introducción
- **Aumento de datos en PLN**
- Algunas librerías para aumento de datos en PLN
- Aumento de datos sin librerías
- Bibliografía

Aumento de datos en PLN

- Posible categorización de los métodos de aumento de datos en PLN:




Imagen: [4]


Aumento de datos en PLN

- Niveles donde se puede aplicar aumento de datos:
 - Nivel de palabra: transformación o sustitución de palabras individuales dentro del texto.
 - Nivel de frase: se altera la estructura y composición de frases completas.
 - Nivel de documento: se altera la estructura y composición de documentos completos.

Imagen: [2]

Aumento de datos en PLN

- Easy Data Augmentation (EDA)



Aumento de datos en PLN

- Generative models
 - Soft Data-to-text generation

original text: Who is the president of the United States?

hard generated text: Joe Biden is currently the serving president of the United States of America.

- Hard Data-to-text generation

original text: 20/03/2023 - 04/04/2023

hard generated text: From 20th of march to the 4th of April.

Imágenes: [4]

Aumento de datos en PLN

- Generative models
 - Text summarization

```
original text: This is a geekforgeeks example. It is part of a larger example and we can probably shorten  
it to create a new sentence.  
summarised text: We can shorten this example to create a new sentence.
```

- Paraphrasing

```
original text: This is a geekforgeeks example.  
paraphrased text: This is an example from geekforgeeks.
```

Imágenes: [4]

Aumento de datos en PLN

- Posible categorización de los métodos de aumento de datos en PLN:
 - Métodos basados en traducción automática (back traslation).




Imagen: [2]

Índice

- Introducción
- Aumento de datos en PLN
- **Algunas librerías para aumento de datos en PLN**
- Aumento de datos sin librerías
- Bibliografía

Algunas librerías para aumento de datos en PLN

- Existen librerías en Python que ayudan a hacer aumento de datos. Algunas de ellas son:
 - NLP Aug
 - TextAugment
 - TextAttack

NLP Aug

- [NLP Aug](#) es una librería que proporciona una implementación eficiente para aumento de datos para texto.
- Lo hace en tres niveles: carácter, palabra y oración.
- Para cada nivel tiene: inserción aleatoria, eliminación aleatoria, alteración del orden y sustitución de sinónimos.
- Puede manejar como entrada texto y audio.

NLP Aug

- Reemplazo de caracteres
 - Además del reemplazo aleatorio, esta librería incluye otros métodos para reemplazar caracteres como son: Optical character recognition y Keyboard augmenter.
 - Optical character recognition: lo que hace es simular errores basándose en los caracteres que tienen una grafía similar.

```
import nlpaug.augmenter.char as nac
import nlpaug.augmenter.word as naw
import nlpaug.augmenter.sentence as nas
import nlpaug.flow as nafc

from nlpaug.util import Action
```

```
text = 'The quick brown fox jumps over the lazy dog .'
print(text)
```

```
aug = nac.OcrAug()
augmented_texts = aug.augment(text, n=3)
print("Original:")
print(text)
print("Augmented Texts:")
print(augmented_texts)
```

Ejemplos

```
Original:
The quick brown fox jumps over the lazy dog .
Augmented Texts:
['The quick bkown fox jumps ovek the lazy dog .', 'The quick 6rown fox jumps ovek the lazy dog .', 'The quick brown f0x jomps
over the la2y dog .']
```

NLP Aug

- Reemplazo de caracteres
 - Keyboard augmenter: genera nuevas instancias reemplazando algunos caracteres por otros que están próximos en el teclado.

```
import nlpaug.augmenter.char as nac
import nlpaug.augmenter.word as naw
import nlpaug.augmenter.sentence as nas
import nlpaug.flow as nafc

from nlpaug.util import Action
```

```
text = 'The quick brown fox jumps over the lazy dog .'
print(text)
```

```
aug = nac.KeyboardAug()
augmented_text = aug.augment(text)
print("Original:")
print(text)
print("Augmented Text:")
print(augmented_text)
```

Original:
The quick brown fox jumps over the lazy dog .
Augmented Text:
The quick brown Gox juJps ocer the lazy dog .

Ejemplos

NLP Aug

- Reemplazo de palabras
 - Ejemplo sustituyendo palabras simulando errores ortográficos

```
aug = naw.SpellingAug()
augmented_texts = aug.augment(text, n=3)
print("Original:")
print(text)
print("Augmented Texts:")
print(augmented_texts)
```

Ejemplos

Original:

The quick brown fox jumps over the lazy dog .

Augmented Texts:

['Tha qchick brown fox jumps ower the lazy dog.', 'Their quick borwn fox jumps over tge lazy dog.', 'The qchick brown fox jumps over the lazy dod.']

NLP Aug

- Reemplazo de palabras
 - Insertar o sustituir palabras atendiendo a la similitud de embeddings.

```
# model_type: word2vec, glove or fasttext
aug = naw.WordEmbsAug(
    model_type='word2vec', model_path=model_dir+'GoogleNews-vectors-negative300.bin',
    action="insert")
augmented_text = aug.augment(text)
print("Original:")
print(text)
print("Augmented Text:")
print(augmented_text)
```

Original:
The quick brown fox jumps over the lazy dog
Augmented Text:
The quick brown fox jumps Alzeari over the lazy Superintendents dog

```
# model_type: word2vec, glove or fasttext
aug = naw.WordEmbsAug(
    model_type='word2vec', model_path=model_dir+'GoogleNews-vectors-negative300.bin',
    action="substitute")
augmented_text = aug.augment(text)
print("Original:")
print(text)
print("Augmented Text:")
print(augmented_text)
```

Original:
The quick brown fox jumps over the lazy dog
Augmented Text:
The easy brown fox jumps around the lazy dog

Ejemplos

NLP Aug

- Reemplazo de palabras:
 - Sustituyendo palabras por sinónimos utilizando WordNet

Synonym Augmenter (WordNet, Spanish)

```
text = 'Un rápido zorro marrón salta sobre el perro perezoso'
aug = naw.SynonymAug(aug_src='wordnet', lang='spa')
augmented_text = aug.augment(text)
print("Original:")
print(text)
print("Augmented Text:")
print(augmented_text)
```

Original:
Un rápido zorro marrón salta sobre el perro perezoso
Augmented Text:
Un rápido zorro marrón salta sobre el can perezoso

Ejemplos

NLP Aug

- Reemplazo de palabras
 - Insertar o sustituir palabras atendiendo a la similitud de embeddings.

Contextual Word Embeddings Augmenter (BERT)

```
# Augment French by BERT
aug = naw.ContextualWordEmbsAug(model_path='bert-base-multilingual-uncased', aug_p=0.1)
text = "Bonjour, J'aimerais une attestation de l'employeur certifiant que je suis en CDI."
augmented_text = aug.augment(text)
print("Original:")
print(text)
print("Augmented Text:")
print(augmented_text)
```

Original:
Bonjour, J'aimerais une attestation de l'employeur certifiant que je suis en CDI.
Augmented Text:
bonjour , j ' aimerais ! attestation de l ' employeur certifiant comment je suis en cdi .

Ejemplos

NLP Aug

- Back Translation

```
import nlpaug.augmenter.word as naw

text = 'The quick brown fox jumped over the lazy dog'
back_translation_aug = naw.BackTranslationAug(
    from_model_name='facebook/wmt19-en-de',
    to_model_name='facebook/wmt19-de-en'
)
back_translation_aug.augment(text)
```

'The speedy brown fox jumped over the lazy dog'

Ejemplos

TextAugment

- [TextAugment](#) es una librería para aumento de datos para texto.
- Se apoya en otras librerías como por ejemplo en la librería nltk para obtener la lista de stopwords y los sinónimos de WordNet, o en otras como Gensim o TextBlob.
- Ejemplo: se sustituye una palabra por otra similar utilizando Word embeddings

Basic example

```
>>> from textaugment import Word2vec, Fasttext
>>> t = Word2vec(model='path/to/gensim/model'or 'gensim model itself')
>>> t.augment('The stories are good')
The films are good
>>> t = Fasttext(model='path/to/gensim/model'or 'gensim model itself')
>>> t.augment('The stories are good')
The films are good
```

[Ejemplos](#)

TextAugment

- Ejemplo: se sustituyen varias palabras por otras similares utilizando Word embeddings

Advanced example

```
>>> runs = 1 # By default.
>>> v = False # verbose mode to replace all the words. If enabled runs is not effective. Used in this p
>>> p = 0.5 # The probability of success of an individual trial. (0.1<p<1.0), default is 0.5. Used by G

>>> word = Word2vec(model='path/to/gensim/model'or'gensim model itself', runs=5, v=False, p=0.5)
>>> word.augment('The stories are good', top_n=10)
The movies are excellent
>>> fast = Fasttext(model='path/to/gensim/model'or'gensim model itself', runs=5, v=False, p=0.5)
>>> fast.augment('The stories are good', top_n=10)
The movies are excellent
```

Ejemplos

TextAugment

- Ejemplo: aumento de datos utilizando WordNet

Basic example

```
>>> import nltk
>>> nltk.download('punkt')
>>> nltk.download('wordnet')
>>> from textaugment import Wordnet
>>> t = Wordnet()
>>> t.augment('In the afternoon, John is going to town')
In the afternoon, John is walking to town
```

[Ejemplos](#)

Advanced example

```
>>> v = True # enable verbs augmentation. By default is True.
>>> n = False # enable nouns augmentation. By default is False.
>>> runs = 1 # number of times to augment a sentence. By default is 1.
>>> p = 0.5 # The probability of success of an individual trial. (0.1<p<1.0), default is 0.5. Used by G

>>> t = Wordnet(v=False, n=True, p=0.5)
>>> t.augment('In the afternoon, John is going to town', top_n=10)
In the afternoon, Joseph is going to town.
```

TextAttack

- TextAttack es un framework en Python, que entre otras cosas tiene una parte que permite hacer aumento de datos para texto.

Augmenting Text: `textattack augment`

Many of the components of TextAttack are useful for data augmentation. The `textattackAugmenter` class uses a transformation and a list of constraints to augment data. We also offer built-in recipes for data augmentation:

- `wordnet` augments text by replacing words with WordNet synonyms
- `embedding` augments text by replacing words with neighbors in the counter-fitted embedding space, with a constraint to ensure their cosine similarity is at least 0.8
- `charswap` augments text by substituting, deleting, inserting, and swapping adjacent characters
- `eda` augments text with a combination of word insertions, substitutions and deletions.
- `checklist` augments text by contraction/extension and by substituting names, locations, numbers.
- `clare` augments text by replacing, inserting, and merging with a pre-trained masked language model.
- `back_trans` augments text by backtranslation approach.
- `back_transcription` augments text by back transcription approach.

TextAttack

- Ejemplo:

```
from textattack.augmentation import WordNetAugmenter

augmenter = WordNetAugmenter()

# Example usage:
sentence = "The quick brown fox jumps over the lazy dog."
augmented_sentence = augmenter.augment(sentence)

print(f"Original Sentence: {sentence}")
print(f"Augmented Sentence: {augmented_sentence}")
```

```
Original Sentence: The quick brown fox jumps over the lazy dog.
Augmented Sentence: ['The quick brown fox jumps over the lazy
click.']
```

[Ejemplos](#)

Índice

- Introducción
- Aumento de datos en PLN
- Algunas librerías para aumento de datos en PLN
- **Aumento de datos sin librerías**
- Bibliografía

Aumento de datos sin librerías

- También es posible hacer aumento de datos sin el soporte de una librería específica para ello.
- Se pueden hacer reemplazos, inserciones, sustituciones, back translation, etc., utilizando recursos para ello (bases de datos léxicas como WordNet, modelos de lenguaje para obtener traducciones, etc.), pero sin usar librerías de AD.
- Se pueden duplicar textos completos o fragmentos como una técnica básica de aumento de datos.
- ...

Resumen

- Las técnicas de aumento de datos hay que aplicarlas antes del entrenamiento y solo sobre estos datos (no sobre el conjunto de validación y test).
- Las técnicas de aumento de datos pueden provocar que el nuevo texto contenga errores o no tenga coherencia, no es una tarea sencilla.
- Es conveniente realizar un estudio previo para ver qué combinación de técnicas de DA es la más adecuada en cada tarea, además de saber qué cantidad de datos se aumenta y si se mejoran los resultados.
 - Puede que no ayuden a mejorar los resultados.

Bibliografía

- [1] Segura Bedmar, I. Transformers. Procesamiento del Lenguaje Natural con Aprendizaje Profundo. Máster en Ciencia y Tecnología Informática. 2023. ([Enlace](#))
- [2] Murel, J. y Kavlakoglu, E. ¿Qué es el aumento de datos? 2024. ([Enlace](#))
- [3] Chen, J., Tam, D., Raffel, C., Bansal, M. y Yang, D. An Empirical Survey of Data Augmentation for Limited Data Learning in NLP. Transactions of the Association for Computational Linguistics 2023; 11 191–211.
doi: https://doi.org/10.1162/tacl_a_00542.
- [4] Geeks for Geeks. Text augmentation techniques in NLP. 2025. ([Enlace](#))